



北京大学

博士研究生学位论文开题报告

题目： 面向人机共生的注意力驱动定
向交互研究

姓 名： 李景聿
学 号： 2301111877
院 系： 计算机学院
专 业： 计算机系统结构
研究方向： 智能无线网络与移动计算
导 师： 许辰人长聘副教授

二〇二六年九月

摘要

随着具身智能与泛在智能物体逐步进入生产和生活环境，人机关系正由人使用单一设备完成离散任务，转向人与多个具身智能体共享物理情境、持续感知彼此状态并动态协作的人机共生。在这一过程中，交互对象、任务进程与环境状态均可能实时变化，用户因而不仅需要“操作设备”，还需要在多个共处对象之间迅速辨认当前目标、自然地表达交互意图，并将指令准确地作用于特定对象。以协同工厂为例，操作人员可能需要在机械臂、移动机器人和智能工位之间连续切换，查看某一对象的状态并随即下达指令，而不应反复退出当前任务以搜索设备。由此，面向多对象的、符合人类空间认知习惯的直观定向交互，成为人机共生时代的新需求。

然而，现有交互方式难以满足这一需求。二维码扫描、设备列表检索和无线配对等方式忽视了指向、朝向与注视中已经包含的空间关注信息；即使用户已明确关注某一对象，仍需在界面中重新查找、确认并连接设备，使物理对象选择、数字身份识别、连接建立与动作执行相互割裂。究其根因，现有系统无法将人的自然注意力直接转化为可靠的对象绑定，只能借助额外的显式步骤恢复交互过程中丢失的注意力信息，因而增加了多对象切换的时间、操作与认知负担。因此，如何捕捉并利用可测量的注意力，在不增加额外操作的前提下准确绑定交互对象，是实现直观定向交互的核心问题。本文围绕**如何挖掘、利用人真实注意力并可靠地转化为高效、精准的定向交互**这一问题展开研究。通过对人类注意力信息由浅入深的挖掘和利用，形成“**所指即所控—所看即所控—所思即所控**”的三种定向交互模式，旨在为未来人机共生提供一个新的交互模式解决方案。具体来说，主要研究工作如下：

(1) 针对广泛普及的手机等手持终端，本文提出基于指向的非接触定向交互系统 **RetroAR**。本文首先发现，手机指向所携带的用户位置和方向信息可由可见光的定向传播特性自然保留。基于此，设计了面向商用手机的可见光定向交互机制：用户以手机闪光灯照射逆反射标签，标签调制反射光并由手机后置摄像头接收，无须检索和连接无线设备。为兼顾数据通信与空间锚定，本文进一步设计动态光标签 **ViTag**，并结合消息级动态兴趣区、快速凸包检测和自适应时空混合编解码，使系统在手机运动、视角变化和复杂光学背景下稳定读取标签并估计六自由度位姿。系统评估表明，**RetroAR** 最远可在约 4m 距离和约 100° 视角下工作；用户研究表明，其交互开销相比传统 Wi-Fi 扫码方案降低 50%，且交互负担更小。**RetroAR** 验证了光学链路利用“指向”提升定向交互效率的可行性，为“所指即所控”提供系统依据；

(2) 针对快速普及的 AR 眼镜终端，本文提出基于互补红外光学通信的定向交互

系统 EchoSight。本文发现，相较于需要主动抬起并对准的手持设备，眼镜方向能够自然贴近用户的观察方向，而红外光束的定向特性可以保留用户注意力指向性，使目标识别与控制一步完成：用户看向目标并做出手势后，眼镜端 SightReader 发射调制红外光，对象端 EchoTag 接收指令并调制反射光，回送身份与状态信息，无须预先注册或建立无线连接。本文进一步设计双路互补光学前端，结合双波段差分信号、对准检测和按需唤醒机制，抑制环境光干扰与非目标响应，实现低时延双向通信。系统评估表明，EchoSight 最远可在约 5m 距离和约 120° 视角下工作；用户研究表明，其交互效率相比二维码扫描和语音控制方案至少提升5倍，且主观负担更低、交互流畅性更好。EchoSight 验证了“视线”比“指向”承载更直观的注意力信息，为“所看即所控”提供系统依据；

（3）针对未来小型化、多模态的新式穿戴设备，本文拟提出利用眼动捕获注意力并结合脑电解码识别意图的定向交互系统 Omnisight。本文首先观察到，用户的眼睛注视朝向和眼镜朝向往往不对齐，且注视方向真正代表了其注意力落点；基于此，设计了由眼动驱动的“物理空间三维鼠标指针”：在AR眼镜上集成基于双目相机的眼动追踪模块，并设计光学云台实现LED波束转向，使光束主动追随用户的真实视线并对准关注目标。与此同时，本文进一步引入基于水凝胶电极的脑电意图识别机制，融合眼动和任务相关脑电信息，区分“看向但不操作”与“主动选择并执行”，以减少因纯注视无交互意图所带来的误操作；Omnisight 的研究旨在探索从“方向近似注意”到“眼动对齐+意图判别”的可行路径，为“所思即所控”提供待验证的系统方案。

关键词：具身智能，人机共生，注意力定向交互，眼动追踪，脑电意图解码

Attention-driven Directional Interaction for Human–Machine Symbiosis

Jingyu Li (Computer Architecture)

Directed by Prof. Chenren Xu

ABSTRACT

As embodied intelligence and ubiquitous intelligent objects increasingly enter production and everyday environments, the relationship between humans and machines is shifting from the use of a single device for discrete tasks toward human–machine symbiosis, in which people and multiple embodied agents share a physical context, continuously perceive one another’s states, and collaborate dynamically. In this setting, interaction targets, task progress, and environmental conditions may all change in real time. Users therefore need not only to operate devices, but also to rapidly identify the intended target among multiple co-located objects, express interaction intent naturally, and direct commands accurately to a specific object. In a collaborative factory, for example, an operator may need to switch continuously among a robotic arm, a mobile robot, and an intelligent workstation, checking the status of one object and immediately issuing a command without repeatedly leaving the current task to search for devices. Intuitive directional interaction that supports multiple objects and conforms to human spatial cognition has thus become a new requirement in the era of human–machine symbiosis.

Existing interaction methods, however, struggle to meet this requirement. QR-code scanning, device-list search, and wireless pairing overlook the spatial focus already conveyed by pointing, orientation, and gaze. Even after users have clearly attended to an object, they must still locate, confirm, and connect to the device again through an interface, separating physical-object selection, digital-identity recognition, connection establishment, and action execution. The fundamental reason is that existing systems cannot directly transform natural human attention into reliable object binding. Instead, they rely on additional explicit steps to recover attention information lost during interaction, thereby increasing the temporal, physical, and cognitive costs of switching among multiple objects. Capturing and exploiting measurable attention to bind an interaction target accurately without additional operations is therefore a central challenge in realizing intuitive directional interaction.

This dissertation investigates **how to uncover and exploit genuine human attention and reliably transform it into efficient and accurate directional interaction**. By progressively exploring and utilizing human attention, it develops three directional interaction paradigms: **“point to control, look to control, and intend to control.”** The goal is to provide a new interaction paradigm for future human–machine symbiosis. The main research contributions are as follows.

(1) For widely used handheld devices such as smartphones, this dissertation presents RetroAR, a pointing-based contactless directional interaction system. It first observes that the user’s position and orientation conveyed by smartphone pointing can be naturally preserved by the directional propagation of visible light. Based on this observation, it designs a visible-light directional interaction mechanism for commodity smartphones: the user illuminates a retroreflective tag with the smartphone flashlight, while the tag modulates the reflected light and the rear camera receives it, eliminating the need to search for and connect to wireless devices. To support both data communication and spatial anchoring, this dissertation further designs the dynamic optical tag ViTag and combines a message-level dynamic region of interest, fast convex-hull detection, and adaptive spatiotemporal hybrid coding and decoding. These techniques enable the system to read tags reliably and estimate six-degree-of-freedom poses under smartphone motion, viewpoint changes, and complex optical backgrounds. System evaluations show that RetroAR operates at distances of up to approximately 4 m and viewing angles of up to approximately 100°. A user study shows that it reduces interaction overhead by 50% compared with a conventional Wi-Fi and QR-code-based approach, while imposing a lower interaction burden. RetroAR demonstrates the feasibility of using an optical link to improve directional interaction efficiency through pointing, providing a system-level basis for “point to control.”

(2) For the rapidly growing class of augmented-reality glasses, this dissertation presents EchoSight, a directional interaction system based on complementary infrared optical communication. Compared with handheld devices that must be actively raised and aimed, the orientation of glasses more naturally follows the user’s viewing direction, while the directionality of an infrared beam preserves the direction of the user’s attention, allowing target identification and control to be completed in a single step. After the user looks at a target and performs a gesture, the glasses-mounted SightReader emits modulated infrared light; the object-mounted EchoTag receives the command, modulates the reflected light, and returns identity and status information without preregistration or a wireless connection. This dissertation further designs

a dual-path complementary optical front end and combines dual-band differential signaling, alignment detection, and on-demand wake-up to suppress ambient-light interference and responses from non-target objects, thereby enabling low-latency bidirectional communication. System evaluations show that EchoSight operates at distances of up to approximately 5 m and viewing angles of up to approximately 120°. A user study shows that its interaction efficiency is at least five times that of QR-code scanning and voice-control approaches, with a lower subjective workload and greater interaction fluency. EchoSight demonstrates that looking conveys attention more intuitively than pointing, providing a system-level basis for “look to control.”

(3) For future miniaturized and multimodal wearable devices, this dissertation proposes Omnisight, a directional interaction system that captures attention through eye tracking and recognizes intent through EEG decoding. It first observes that the direction of a user’s gaze is often misaligned with the orientation of the glasses and that gaze direction more faithfully indicates where the user’s attention is focused. Based on this observation, it designs an eye-tracking-driven “three-dimensional mouse pointer in physical space.” A binocular-camera-based eye-tracking module is integrated into AR glasses, and an optical gimbal steers an LED beam so that it actively follows the user’s actual line of sight and aligns with the attended target. Meanwhile, this dissertation introduces an EEG-based intent-recognition mechanism using hydrogel electrodes. By combining eye-tracking data with task-related EEG signals, the mechanism distinguishes between “looking without acting” and “actively selecting and executing,” thereby reducing unintended operations caused by gaze without interaction intent. The Omnisight study aims to explore a feasible path from approximating attention through device orientation to aligning with gaze and discriminating intent, providing a system design to be validated for “intend to control.”

KEYWORDS: Embodied intelligence, Human–machine symbiosis, Attention-aware interaction, Directional interaction, Eye tracking, EEG

目录

第一章 研究背景与挑战	1
1.1 具身智能与人机共生的发展背景	1
1.2 人机共生环境中的注意力驱动的定向交互	3
1.3 面向定向交互的通信感知技术发展	6
第二章 研究现状	8
2.1 定向光学链路	8
2.2 注意力驱动的直观交互	9
2.3 基于眼动、脑电信号的意图识别	11
第三章 本文工作及当前进展	14
3.1 技术挑战与研究思路	14
3.2 本文主要工作及进展	15
第四章 研究计划	17
4.1 论文提纲	17
4.2 时间进度安排	17
参考文献	19

第一章 研究背景与挑战

1.1 具身智能与人机共生的发展背景

人工智能正在由以数字内容处理为主的软件能力，进一步走向能够感知环境、理解任务并作用于物理世界的具身智能。机器人、智能汽车、可穿戴设备、智能家居和新型生产装备持续进入真实场景，使计算不再局限于屏幕之内，而是分布在具有不同形态、位置和功能的物理对象之中。由此，人与机器的关系也开始从“人使用单一工具”转向“人与多类智能体共享环境并协同完成任务”：机器不仅接收预先定义的指令，还会根据环境状态提供信息、提出建议乃至执行动作；人则需要在动态过程中理解机器状态、表达目标并保持必要的监督。

这一变化已成为全球人工智能竞争和产业政策的重要方向。我国《“十四五”机器人产业发展规划》将机器人视为引领产业数字化发展和智能化升级的重要载体，并面向制造、医疗、养老和公共服务等场景推动产品研制与应用拓展[1]；2025 年国务院发布《关于深入实施“人工智能+”行动的意见》，进一步提出推动人工智能与经济社会各领域广泛深度融合，加快形成人机协同、跨界融合、共创分享的智能经济和智能社会新形态[2]，国家发展改革委随后将人机协作、人机交互和虚实融合概括为智能社会的重要特征，并提出面向人机共生布局新型智能基础设施[3]。国际上，美国《人工智能行动计划》把自动驾驶、无人机和机器人列为人工智能作用于物理世界的重要形态，提出支持下一代制造并识别机器人制造的供应链挑战[4]；欧盟“Apply AI”战略则把机器人、制造、交通和医疗列为重点领域，通过人工智能工厂、测试验证设施和监管沙盒推动技术由实验室走向市场，同时强调可信、安全和以人为本的应用[5]。不同经济体在发展路径和治理方式上各有侧重，但共同表明，人工智能竞争已由模型和算力延伸到智能机器能否进入物理环境、与人协作并形成可持续的生产与服务能力。

政策推动正快速转化为全球产业投入和终端供给。在国内，国家税务总局数据显示，2026 年 1—5 月我国具身智能产业企业销售收入同比增长 22.4%，机器人本体与整机制造企业销售收入增长 30.1%，工业企业购进具身智能机器人的金额同比增长 2.3 倍[6]；2026 世界机器人大会发布的信息显示，我国人形机器人整机产品已超过 400 款，上半年出货量超过 4 万台，机器人已在多个物流中心参与包裹分拣、在近百家药店承担药品拣选，并开始进入景区讲解、社区巡逻和商业服务等场景[7]。在海外，宝马于 2026 年在德国莱比锡工厂启动人形机器人 AEON 的生产试点，使其参与高压电池装配、零部件生产和物料配送；此前美国斯帕坦堡工厂的 Figure 02 已在十个月内参

与超过 3 万辆汽车的生产[8]。这些中外案例说明，具身智能正由样机展示迁移到真实生产与服务现场，机器也由隔离区域内的固定自动化设备逐步转向能够移动、感知并与工作人员共享作业空间的协作主体。



图 1.1 全球具身智能由政策牵引、产业部署到人机共生挑战的发展态势

然而，终端数量和展示能力的增长，并不等于人机共生已经成熟。现有案例大多仍集中在物流搬运、部件取放和巡检等边界清晰的任务中，常以少量设备、限定工位或试点项目运行。即使在相对结构化的汽车工厂，宝马仍需先建立统一的数据与接口体系，并在部署过程中增设安全隔离设施、改善厂区 5G 覆盖，再将机器人逐步接入生产流程[8]。面向开放环境的行业观察也指出，机器人虽然可以在演示中完成任务，但其速度和可靠性往往尚不足以直接进入工业部署；当不可预测的人进入环境后，机器还必须理解人的语言、手势、姿态和空间指代[9]。

这一现状促使我们思考：当具身智能设备已经开始走进工厂、商场、社区和家庭，为什么自然、稳定的人机共生仍未成为普遍现实？表面上看，问题表现为机器灵巧性不足、续航有限或模型泛化能力不够；从人机系统的角度看，更深层的原因在于，当前技术主要解决“机器能否完成一个动作”，却尚未充分解决“人如何在复杂现场找到机器、让机器理解自己，并在多个对象之间建立可靠协作关系”。实验室中的一次成功执行通常具有预设目标、已知对象和受控环境，而真实共生场景中的目标、参与者与任务状态会持续变化，两者所需的系统能力并不相同。

首先，现实环境具有开放性和不确定性。物体位置、光照、遮挡和人员活动不断变化，同一指令在不同场景下可能对应不同对象与动作。机器需要把感知结果与物理

实体、任务上下文和安全边界联系起来，而不能只复现训练数据中的动作序列。当感知置信度下降或环境发生变化时，系统还要知道何时暂停、请求帮助或把控制权交还给人。这使具身智能的规模化应用不只是模型泛化问题，也是现场状态能否被共同理解的问题。

其次，人机共生环境具有多对象和多主体特征。许多系统仍以“一名用户、一块屏幕、一台预先连接的设备”为基本假设，依靠应用程序、设备名称和菜单层级组织操作。当用户面对多台外观相似的机器人、显示器、传感器或家电时，必须先从网络列表中识别目标，再完成搜索、配对、选择和控制。人在物理空间中已经通过位置、朝向或注视表达了关注对象，数字系统却经常丢失这一信息，导致物理对象、数字身份和交互会话相互分离。

再次，具身智能直接作用于现实世界，交互错误会产生物理后果。系统若选错对象，指令可能被相邻设备执行；若把短暂观察误判为控制意图，又可能触发并非用户所愿的动作。为了规避风险，现有部署常通过隔离区、固定流程和专业人员监督限制机器行为，但这些措施也限制了机器与普通用户自然接触的范围。人机共生因此需要在效率与安全之间取得平衡：既不能让用户为每个简单动作经历冗长配置，也不能把模糊的方向、语音或注视直接解释为高风险命令。

由上述原因可以归纳出四项共性挑战：**一是环境适应挑战**，机器需要在动态、非结构化现场保持可靠感知和行动；**二是对象绑定挑战**，系统需要确认用户面对的物理对象及其唯一数字身份；**三是意图理解挑战**，系统需要区分偶然经过、一般观察和主动操作，并对不同风险动作采用分级确认；**四是持续协作挑战**，机器需要在人员移动、目标切换和局部通信中断时维持一致的任务状态与反馈。前一项主要决定机器是否“能做”，后三项则共同决定人与机器是否“能够一起做”。

综上，具身智能的政策支持、产业投入和终端供给正在全球范围内快速增长，但从可演示、可试点走向可普遍共生，仍存在明显的交互鸿沟。人机共生并不是简单增加机器数量，也不是让机器完全替代人，而是要求人能够自然表达目标，机器能够准确识别对象和意图，双方能够围绕同一任务持续交换状态并处理异常。要跨越这道“最后一公里”，需要从现场空间关系出发重新审视交互入口，使目标发现、身份确认、动作执行与结果反馈围绕同一现实对象连续展开。定向交互由此成为连接具身智能能力与人机共生体验的重要基础。

1.2 人机共生环境中的注意力驱动的定向交互

人机共生环境中的交互具有明确的对象性。用户并不是抽象地向整个环境发出命令，而是在特定时刻希望查看、询问或控制某一个现实对象，例如眼前的机械臂、医

疗设备或灯具。当可交互对象由一块屏幕扩展为散布在空间中的大量机器，系统必须先于具体命令回答“用户要与哪一个对象交互”。本文所称的**定向交互**，即利用用户、交互设备与环境目标之间的空间方向关系，将人的指向映射到特定物理对象，并围绕该对象完成发现、身份确认、命令执行与结果反馈。“定向”既表示人的行为具有空间目标，也要求后续信息仍抵达这个目标，而不是在连接阶段重新退化为对设备列表的搜索。

人的注意力为方向提供了自然线索。人在准备使用物体前，通常会靠近、转头、注视或伸手指向它。不过，心理关注也可以在眼球不转动时发生隐蔽转移，因此注意力并不等同于单一传感器读数，视线只是重要但不完备的观测量[10]。本文所称的注意力驱动交互，是指系统利用指向、头向、视线、手部动作和任务上下文估计用户关注的对象，并据此调节目标选择与交互流程；注意力驱动的定向交互则进一步把“用户关注哪里”转化为“系统应与哪一个现实对象建立交互”。其目的不是用眼睛替代鼠标，而是利用人已经自然表达的空间关注，减少重复搜索、命名和配对。

定向交互的发展始于对自然指代行为的数字化。1980年，麻省理工学院的“Put-That-There”系统将手势指向与语音结合，由方向回答“哪个对象和位置”，由语音表达动作[11]。1990年，Jacob将眼动用于界面目标选择，同时指出眼睛既承担观察任务，又可能被解释为控制命令，从而产生“米达斯接触”问题[12]。进入普适计算阶段，研究重点由操作一台计算机转向管理多设备环境中的注意力。卡内基梅隆大学2002年提出Project Aura，将人的注意力视为普适计算中最稀缺的资源，通过感知用户任务与可用设备减少配置和迁移造成的打断[13]；随后形成的注意用户界面主张系统根据自己处于注意力前景还是背景决定何时响应[14]。EyePliances给出了现实家电实例：电视在无人观看时暂停，AuraLamp只有在用户看向它时才接受语音命令[15]。这些工作确立了“以方向确定目标、以其他线索确认操作”的基本范式。

移动计算、增强现实和可穿戴感知进一步把这一范式带入三维空间。ubiGaze利用头戴眼动设备把凝视手势附着到真实物体[16]，Gaze+Pinch则以凝视指定目标、以捏合手势确认和操纵，形成“眼睛选择、手部承诺”的多模态分工[17]。面向物联网，Snap-To-It、Scenariot和BLEselect分别探索借助目标图像、增强现实空间映射和蓝牙到达角选择现实设备[18–20]。目前研究又开始把眼动、手势、场景视觉和历史行为结合，用注意力帮助情境智能体理解用户任务。2025年的研究表明，将此前的物体注视轨迹加入视觉语言模型上下文，可以改善模型对当前关注对象和下一步交互对象的判断[21]。研究重心由瞬时“看向哪里”逐步扩展到持续的对象关联与任务情境。

注意力驱动交互也已进入商业空间计算平台。HoloLens 2支持头部凝视、眼动凝视和凝视停留，适用于维修人员双手被工具占用且现场噪声不利于语音控制的场

景[22]；Apple Vision Pro 则把“看向对象并捏合手指”作为 visionOS 的主要间接交互方式[23]。这些系统证明了注意力方向可以减少光标移动和远距离伸手，但其成熟体验主要建立在平台已知的窗口、三维模型和空间锚点之上。对于未预先建模的机械臂、家电或公共设施，系统仍需完成物体识别、数字身份关联和通信授权，才能把一次“看向”转化为现实操作。我们不禁思考：**当设备已经能够测量用户的指向、头向和视线，为什么面向现实对象的注意力驱动定向交互仍未成为普遍能力？**例如，在装有两台同型号机械臂的车间中，眼镜可能测得用户正看向左侧机械臂，相机也识别出“机械臂”类别，但无线网络只返回两个相似的设备名称。系统仍不知道左侧实体对应哪个网络地址，也无法保证启动命令不会发给另一台机器。问题的关键因此不是能否获得一个方向，而是该方向能否被可靠地转化为正确对象、真实意图和一致的信息通道。

第一项瓶颈是注意方向难以与正确物理对象可靠绑定。手持设备指向较明确，却要求用户举起并对准；头向便于持续获取，却只能粗略表示视野中心；眼动最接近视觉注意，但会受到标定误差、个体差异、设备滑移和自然扫视影响。日常条件下眼动的准确度和精密度会随用户、目标位置与设备状态明显变化[24]；在三维场景中，角度误差还会随距离放大，同一视线附近可能存在相邻、同类或不同深度的多个物体。将测得的 gaze point 映射为具有语义的 gaze object，本身仍是尚未完全解决的问题[25]。而即使相机确定了物体的位置和类别，也不能直接证明该物体就是无线网络中的某个地址。因此，注意方向、物理实体和数字身份之间仍存在断裂。

第二项瓶颈是关注对象难以直接转化为安全、连续的交互闭环。用户查看灯具可能只是观察环境，并不意味着希望开灯；人在寻找零件或巡视设备时也会自然扫过大量对象。若每次注视都触发命令，会产生严重误操作；若一律要求长时间停留、语音或手势确认，又会抵消注意力交互的效率。Gaze+Pinch 通过“凝视选择、手势确认”缓解米达斯接触，但眼手配合、目标切换和持续操纵仍缺乏统一规则[26]。更重要的是，相机感知和 Wi-Fi、蓝牙发现分别回答“看见了什么”和“附近有什么设备”，却不能天然保证被感知、被寻址、接收命令和返回反馈的是同一对象。二维码、预注册数据库或空间锚点能够维护这种映射，但会增加扫描、部署和更新开销，并在对象移动或密集部署时失效。

由此可归纳出三项核心挑战：**一是定向感知挑战**，需要在用户移动、设备滑移和遮挡条件下恢复注意方向，并将带误差的方向映射到正确物理对象；**二是意图判别挑战**，需要区分偶然看见、持续关注与主动操作，并依据任务风险采用不同强度的确认；**三是链路一致性挑战**，需要沿同一空间方向核验对象身份、建立信息通道，并保证交互全过程始终作用于同一目标。前两项决定系统能否理解人“关注什么、是否操作”，

第三项决定这种理解能否安全地作用于现实世界。

综上，注意力驱动的定向交互已经由屏幕指向和凝视输入，发展到多设备注意力管理、空间计算与情境智能，但现有成果仍未完全贯通现实对象感知、身份确认和数据传输。要使“所指”“所看”可靠地转化为“所交互”，一方面需要**定向感知技术**提取注意方向并定位目标，另一方面需要**定向通信技术**利用空间约束核验目标身份、建立局部链路并返回反馈。光学技术同时具备成像感知、视距传播与波束空间约束能力，为统一注意方向、物理对象和信息通道提供了自然基础。

1.3 面向定向交互的通信感知技术发展

上一节指出，注意力驱动定向交互需要把人的注意方向绑定到物理对象，再将其转化为安全、连续的数字连接，即同时回答“目标在哪里”和“目标是谁”。视觉感知能够恢复对象的位置、类别和姿态，射频通信能够发现节点并维持连接，但二者的空间对象与网络身份并不天然对应。光学信号既可成像又可传输数据，并受光束方向、接收视场和遮挡关系约束，因此为统一注意方向、现实对象与信息通道提供了自然基础。

从实现机制看，光学通信通常采用强度调制与直接检测：发光器件以人眼难以察觉的速度改变光强，光电二极管或相机将接收光转换为电信号并恢复数据。发射光束越窄、接收视场越小，链路覆盖的空间范围越集中，不同方向上的对象也越容易分离。因此，光学用于定向交互的价值不仅在于频谱和速率，更在于通过物理传播范围缩小候选集合，使信息来源与用户面对的空间方向建立直接联系。

光学技术首先被用于**对象感知与空间锚定**。相机通过外观、二维码或人工标记识别目标，1999年的ARToolKit推动了视觉标记在增强现实注册中的应用[27]；2002年的FindIT则使用手持光束唤醒匹配标签，使“照向哪里”直接决定“查询谁”[28]。InfoLED、LightAnchors等系统进一步利用设备指示灯或场景点光源，将数字信息锚定到现实位置[29, 30]。这一路线建立了空间选择能力，但静态标记只能提供预存信息，识别结果仍需借助额外映射才能转化为控制链路。

高效LED与光电器件的普及推动技术由对象识别走向**双向光学通信**。2011年，IEEE 802.15.7定义了短距离可见光通信机制，LiFi随后将单条光链路扩展为支持多用户接入和移动切换的无线网络[31, 32]。产业界也开始推动落地：Signify于2019年推出Trulifi商用系统，2023年发布的IEEE 802.11bb则将光通信纳入无线局域网标准体系[33, 34]。这些里程碑表明，光已由单向信息载体发展为可与现有网络协同的接入媒介。

然而，大量现实对象若采用主动光发射器回传，会带来持续供电、方向对准和硬

件成本问题。由此形成的**无源光学回传**路线，使用主动读写器照射目标，以逆反射材料将入射光送回光源附近，并通过液晶等低功耗调制器在回波上编码身份与状态。**Retro-VLC**、**PassiveVLC** 和 **TurboBoost** 等工作逐步验证并提升了这类双向链路的距离、速率与环境适应性[35–37]。当手机或眼镜指向目标时，窄光束先筛选候选对象，近原路返回的信号再确认其身份，使“指向哪个物体”与“数据来自哪个设备”在同一现场链路中得到验证，交互入口也由手持指向逐步走向头向和视线驱动。

方向性既是光学的优势，也是其限制。窄光束和小接收视场能够缩小候选范围、降低误绑定，却容易受到环境光、入射角、人体遮挡和用户移动影响，不适合独立承担长时间连接。射频链路则覆盖广、非视距能力强且基础设施成熟，但难以判断用户关注的是哪个现实对象。这种互补性推动技术路线走向**光学与射频混合**：定向光链路负责发现目标并读取身份、能力或临时凭据，**Wi-Fi**、**蓝牙**等射频网络随后承载可穿越短时遮挡的持续会话。已有 **LiFi** 与 **Wi-Fi** 混合网络也验证了局部光接入与广域无线覆盖的协同价值[38]。

相较于单一媒介，混合路线可以在建立射频连接前利用空间方向缩小候选范围，并在选择完成后容忍转头、移动与暂时遮挡；同时，低功耗光标签只需交换身份、授权和少量状态，大数据传输与长期控制可以复用成熟射频设施。其关键不在于简单并列两条链路，而在于保证光学身份与射频地址一致，并合理设计遮挡后的保持、重新验证和目标切换机制，从而将第 1.2 节提出的定向感知、意图判别和链路一致性落实为完整交互流程。

基于上述脉络，本文以光学通信感知一体化作为注意方向与现实对象之间的入口，并探索光学与射频协同：首先利用手机指向和可见光逆反射实现对象选择与信息回传，继而将入口迁移到智能眼镜和近红外双向链路，进一步结合眼动追踪、可调光束与多模态意图判别，并在目标验证后转入可持续的无线会话，使交互由“所指”走向“所看”与“所欲”。

第二章 研究现状

2.1 定向光学链路

定向交互需要在“人所指向或观察的对象”与“实际交换数据的设备”之间建立直接对应。射频链路具有覆盖广、穿透性强和网络生态成熟等优势，却通常将多个空间方向上的设备纳入同一发现范围。光学无线通信则受发射光束、接收视场和视距关系约束，能够在物理层将通信范围限定在局部空间。因而，光学链路的方向性不仅是一种信道特性，也可以成为对象选择和身份绑定的交互资源。

早期定向光学系统主要使用主动发光器或静态光学标记。FindIT Flashlight 使用手持光束唤醒并定位特定标签，展示了用“照向”动作筛选附近物体的可行性[28]。PixNet 使用 LCD 与摄像头建立具有空间分辨能力的光学链路[39]；InfoLED 和 LightAnchors 则将现有 LED 指示灯复用为设备身份与增强现实空间锚点[29, 30]。这类方法能够把数字信息附着到具体位置，但主动发光会增加对象端功耗，而静态标记不能根据对象状态动态返回信息。

无源光学链路为低功耗反向通信提供了另一条技术路径。典型系统包含主动读写器和无源或低功耗光标签：读写器负责发射照明或调制光，逆反射材料把入射光返回光源方向，液晶等空间光调制器再通过改变光学状态将数据调制到回波中。Retro-VLC 首次将逆反射材料与液晶调制器结合，构建了面向移动和物联网设备的双工可见光反向链路[35]。PassiveVLC 进一步通过器件与编码协同设计，提高无电池标签通信的可用性[36]。

在此基础上，后续研究主要围绕数据率、距离、抗环境光干扰以及多标签接入展开。TurboBoosting 利用多级调制和链路协同设计提升可见光反向散射的通信性能[37]。参考报告对这条技术脉络的总结表明，现有系统已在物理层实现低功耗上行，但其常用设计仍是“单读写器—单标签”链路；当多个标签的反射信号同时到达接收器时，传统时分机制会使延迟随节点数量增长。因而，如何利用光束的空间可分性避免非目标响应，是无源光学网络从单链路走向密集场景的核心问题。

上述工作主要将无源光学链路视为低功耗通信系统，而 RetroAR 进一步将光束方向解释为用户的目标选择。该系统以商用智能手机的闪光灯和后置摄像头作为读写器，并使用多像素液晶逆反射标签 ViTag 承担数据传输与空间锚定。标签在时域与空间域中编码返回数据，手机在解码的同时进行标签跟踪和六自由度位姿估计。这一设计使“手机指向”、“设备识别”与“获取控制信息”在同一光学链路中完成，避免了




图 2.1 定向光学链路的技术路线与交互形态（占位图）

再从 Wi-Fi 或蓝牙列表中查找目标[40]。

EchoSight 则把无源定向链路从手持设备迁移到智能眼镜。系统包含眼镜端读写器 SightReader 和对象端标签 EchoTag，通过双光学元件的近红外链路实现局部双向数据交换。用户看向目标并作出手势后，标签返回设备身份和交互菜单，后续指令仍被限定在当前光学链路中。其系统评估表明，该链路可以支持房间尺度的交互距离和视角，说明近红外逆反射链路可以被整合到轻量级佩戴式交互系统中[41]。

定向光学链路的研究因此呈现出从“实现通信”到“支持空间交互”的演进。但现有系统仍存在三方面局限。首先，光学接收会受环境光、反射噪声、观察距离和入射角影响，移动过程中需要同时保证检测、跟踪与解码稳定性。其次，手机或眼镜的光轴只能表示设备方向，不能完全代替用户的真实视线与操作意图。最后，全光会话对视距的依赖会限制遮挡条件下的持续交互。如何在保留光学方向性的同时，使空间选择、真实注视和持续会话相互配合，仍是定向光学交互需要解决的问题。

2.2 注意力驱动的直观交互

智能环境中的上下文感知交互，通过利用用户的位置、朝向、动作和周边物体状态，减少人对菜单层级与设备名称的记忆负担。在多对象环境中，这类系统通常需要回答两个问题：用户当前关注的是哪一个对象，以及用户希望对该对象执行什么动作。因此，注意力驱动交互并不是单一的输入模态，而是将指向、头向、注视等注意代理线索贯穿到对象发现、身份绑定和动作反馈的交互方法。

对象识别是这类研究的主要起点。二维码、ARTag 等人工标记可以同时编码身份与提供几何定位，具有识别简单、结果明确的优势；其局限是标记需要处于摄像头视野内，还可能破坏物体外观。基于自然特征的方法可以避免附加可见标记，但在弱纹理、外观相似、快速运动或局部遮挡时易出现不稳定，并且需要较多计算资源[42]。Snap-to-it 允许用户通过拍摄目标图像完成偶发式设备选择，但需要云端识别与预先准

备的视觉数据[18]。

为了降低显式标记与纯视觉匹配的局限，一些工作开始利用射频测位或异构传感信息缩小候选范围。**Bluewave** 把短上下文信息嵌入蓝牙设备名称，以降低连接前的信息获取成本[43]。**Scenariot** 结合超宽带定位与同步定位建图，将智能对象映射到增强现实场景中[19]。**BLEselect** 使用智能眼镜上的蓝牙到达角估计感知手势方向，将空间指向与无线身份关联[20]。**IRIS** 则将指环的无线感知与手机图像、惯性数据结合，实现智能家居的指向控制[44]。这些方法提高了空间分辨能力，但通常仍需要设备预注册、环境建图或局域网络连接。




图 2.2 注意力驱动的对象绑定与双向交互流程（占位图）

另一类研究关注虚拟世界与物理对象之间的双向同步。**BISHARE** 支持智能手机与头戴式增强现实设备之间的双向绑定，使手机的物理位置和姿态可被头显感知，手机又可作为虚拟内容的控制器[45]。**Sketched Reality** 将用户绘制的虚拟草图转化为物理机器人动作[46]；**MechARspace** 则在增强现实界面与可动玩具之间建立实时映射[47]。这些系统表明，直观交互不应止于识别一个对象，还需要使物理状态、虚拟表示和用户动作持续一致。

然而，现有双向虚实系统在“识别对象”与“控制对象”之间往往使用不同机制。**InfoLED** 与 **LightAnchors** 通过光学方式获取就地信息，但对设备的后续控制仍依赖蓝牙或 Wi-Fi[29, 30]。当场景中存在多个同类对象时，系统必须另外维护光学识别结果与无线地址的映射。这种分离设计虽然可以充分利用成熟网络，却容易在目标切换、设备移动或数据库更新不及时时形成对象绑定断点。

RetroAR 与 **EchoSight** 的重要转变，在于将用户已经表达的空间关注直接保留到数据链路中。**RetroAR** 以手机指向作为强外显选择线索，用户必须主动举起设备并对准目标，因而“指向”本身同时表达了注意范围与一定程度的交互意愿[40]。**EchoSight** 转而使用头戴式设备的朝向近似用户的观察方向，使目标识别、菜单获取与控制命令都可以通过局部光学链路完成[41]。其用户研究将交互时间分解到识别、连接与命令执行阶段，结果表明，在短时物联网任务中，简化目标识别和连接准备对整体流畅性

的影响大于单纯改善数据传输延迟。

现有研究已经证明，方向、位置与注视等线索可以降低多对象选择的显式操作开销，但仍未完全解决注意力的两重不确定性。第一，设备光轴、头部朝向与眼球视线并不总是一致，密集目标中仅依靠机身方向可能无法区分相邻对象。第二，准确的视线交点只说明用户正在观察，不能单独证明用户准备执行操作。因此，注意力驱动交互的下一步不只是换用更精确的眼动传感器，还需要研究视线与操作意图的区分。

2.3 基于眼动、脑电信号的意图识别

眼动是注意力交互中最直接的可观测信号之一。早期凝视交互已尝试使用视线指定界面元素，并通过凝视停留或辅助输入完成选择[12]。与头向和手持设备指向相比，眼动的转移速度快、动作幅度小，能够在不占用双手的条件下指出视野中的感兴趣区域。随着眼动相机逐渐集成到头戴式设备中，凝视也成为增强现实和空间计算中用于目标指定、菜单导航和渲染优化的重要通道。

但凝视不是一种天然无误差的指针。眼动测量的准确度与精密度受标定质量、注视位置、用户个体差异和设备滑移影响，实际误差会直接限制相邻目标的最小可分距离[24]。同时，人类视线在浏览环境时会自然扫过大量非操作对象。若系统把“看到”直接解释为“选中”，就会产生所谓的“米达斯接触”问题；若通过较长的凝视停留时间避免误触发，又会降低操作速度并带来视觉疲劳。

因此，大量凝视交互采用“视线定位+显式确认”的多模态思路。眼动先把较大的视觉场景缩小为少量候选目标，手势、按键、语音或肌电信号再确认动作。这种分工能够避免对眼动信号赋予过多含义，但其效率取决于确认模态是否与当前任务兼容。在双手被占用、必须保持安静或不方便作出明显动作的场景中，额外手势与语音可能重新引入交互负担。这促使研究者进一步探索能否从生理信号中获得与注意和行动准备相关的证据。

脑电图（Electroencephalography, EEG）具有无创、时间分辨率高和硬件可穿戴化等特点，是脑机接口中应用最广泛的信号之一。根据信号是否由外部刺激诱发，相关方法可概括为诱发电位与自发脑活动两类。前者包括P300、稳态视觉诱发电位（Steady-State Visual Evoked Potential, SSVEP）等，通常通过用户对特定刺激的注意识别目标；后者包括感觉运动节律、运动想象以及与认知状态相关的频带特征。现有综述表明，EEG脑机接口已形成从信号采集、预处理、特征提取到分类的完整技术链，但实用系统仍受低信噪比、非平稳性和个体差异限制[48]。

P300是与低概率、任务相关刺激相联系的事件相关电位。Farwell和Donchin提出的P300字符输入系统使用稀有刺激范式，通过检测用户所关注行列诱发的P300响应

确定目标字符[49]。这类方法不需要用户产生明显肢体动作，但为了对抗单次事件相关电位较弱的信噪比，往往需要多次刺激和时间锁定平均。当它被用于短时现场交互时，系统需要在准确率、响应时间和用户注意负担之间进行权衡。

SSVEP 利用用户观察周期性视觉刺激时，视觉皮层产生与刺激频率及其谐波相关的稳态响应。系统可以为多个界面选项分配不同频率或编码，再根据 EEG 的频谱或相关性判断用户关注的选项。这类系统通常具有相对稳定的频域特征和较少用户训练要求，是视觉脑机接口的主要路径之一[50]。但多个持续闪烁的刺激会影响视觉舒适度，且 SSVEP 本质上识别的是对特定刺激的选择性注意，未必等价于对现实对象执行某个控制动作的自发意图。

图片占位：眼动与 EEG 协同的意图识别框架

建议内容：眼动给出空间目标，EEG 给出任务相关证据，置信融合后输出“观察/准备操作”，再决定直接执行或请求确认。

图 2.3 眼动与脑电信号辅助的分级意图判别框架（占位图）

相较诱发电位，基于运动想象、感觉运动节律或其他自发特征的方法不必在环境中布置持续闪烁的外部刺激，更接近“从内部行动准备中识别意图”的目标。但这类信号对用户训练、个体化标定和电极质量更为敏感，也易受眼电、肌电和日常身体运动的伪迹干扰。这意味着，在可穿戴交互中直接使用 EEG 代替手势或按键，往往得不偿失；更可行的方向是把它视为一种辅助证据，而不是唯一命令通道。

从多模态融合角度看，眼动与 EEG 具有互补性。眼动能够快速给出用户正在观察的空间区域，但无法独立判断操作意图；EEG 可能提供与选择性注意、行动准备或认知评估相关的时序证据，却缺少对现实空间目标的精确指向。若先用眼动缩小对象范围，再在短时窗内利用 EEG 评估意图置信度，理论上可以减少单一模态的二义性。但融合系统必须处理两种信号的时间对齐、不同用户的模型适配、头部运动伪迹以及误判成本不对称等问题。

现有凝视与脑机接口研究多数聚焦屏幕上的离散选项、输入效率或辅助控制，而少有工作将其与现实世界多对象的身份绑定和通信会话同时考虑。EchoSight 已指出，对于高密度目标，可以结合头部朝向获取粗粒度关注范围，再使用眼动完成精细对准[41]。但眼动驱动光束定向、视线到物理标签的实时标定，以及 EEG 能否在自然观察中辅助区分“看见”与“准备操作”，仍缺少系统性验证。

研究空白与本文定位。 现有工作已分别发展了方向性光学通信、上下文感知对象交互以及眼动/EEG 人机输入，但三个层面尚未形成一条连贯、可验证的行动链。方向性通信不必然等于真实注视，准确注视也不必然表示主动意图；当光学选择转入持续无线会话后，物理对象与数字身份的一致性也需要继续维持。

本文因此不把光学通信、眼动与 EEG 视为彼此并列的传感器，而是分别用于对象选择、视线对齐和意图判别。RetroAR、EchoSight 与 Omnisight 对应“所指即所控”、“所看即所控”与“所思即所控”三个逐级深入的层次。前两项工作验证方向性光学链路在手持与佩戴式交互中的可行性，第三项工作则进一步面向真实视线、操作意图与持续会话之间的断点展开研究。

表2.1按目标线索、意图处理及会话方式概括本文三项工作的定位。其中 Omnisight 栏表示拟研究与验证的能力，不作为已有性能结论。

表 2.1 三项工作在注意力驱动交互链中的定位

工作	目标线索与对齐	意图处理	会话方式
RetroAR	手机指向、光束选物	由用户持机指向表达	局部可见光链路
EchoSight	眼镜光路近似观察方向	手势确认、未实测眼动	双向近红外光链路
Omnisight	实测眼动驱动光束	眼动/EEG 辅助判别	光选择、无线持续会话

第三章 本文工作及当前进展

3.1 技术挑战与研究思路

在人机共生环境中，用户需要在多个共处对象之间快速切换，并把自然产生的空间关注转化为针对特定对象的操作。要实现这一目标，系统不能只解决单次识别或通信问题，而需要贯通“线索获取—对象绑定—意图确认—会话维持—动作反馈”的完整交互链。其关键技术挑战可归纳为以下三个方面。

注意力的可靠获取与空间对齐。 指向、头部朝向和眼球视线都能提供目标线索，但三者与真实关注对象之间存在不同程度的偏差。手机指向需要用户主动举机并保持对准；眼镜机身方向虽然更接近日常观察，却不能代表眼球实际注视点；实测眼动又受到标定误差、头部运动、目标距离和相邻目标间距的影响。因此，首先需要明确不同线索能够提供何种空间约束，并研究如何利用方向性光路将这些线索稳定地对齐到唯一物理对象，而不能简单地把设备朝向等同于人的注意力。

目标注视与操作意图的可靠区分。 即使系统能够准确判断用户正在看哪个对象，也不能据此认定用户准备执行操作。日常观察、状态检查、偶然扫视和主动选择可能产生相似的眼动表现，若直接以注视触发控制，容易产生“米达斯接触”式误操作。显式按钮或语音确认能够降低二义性，却会重新引入动作和认知开销；脑电等生理信号可能提供任务相关证据，但同时面临噪声、运动伪迹、个体差异和佩戴负担。因此，需要在相同任务中比较眼动、脑电、多模态融合与显式确认，判断生理信号是否真正带来足以覆盖其成本的增量收益。

物理对象绑定与持续会话的一致性。 定向光学链路适合利用空间方向发现目标和确认身份，但可能因转头、移动或遮挡而中断；蓝牙等无线链路适合持续传输，却不能天然保证设备列表中的数字身份就是用户刚刚关注的物理对象。若目标选择与后续通信彼此独立，便可能出现选中对象与实际控制设备不一致、切换后会话未及时更新等问题。因此，需要设计从光学目标标识到无线设备身份的可验证绑定，并处理授权、超时、切换、重绑定和会话恢复，使注意力不仅完成一次选择，还能可靠地贯穿后续控制与反馈。

研究思路。 本文按照注意力由间接到直接、系统能力由目标选择到行动判别的顺序展开研究。首先，RetroAR 将手机指向外化为可见光链路，验证方向性光学机制能否在同一动作中完成目标发现、身份读取与空间定位；其次，EchoSight 将交互入口迁移到智能眼镜，以双向近红外链路研究更接近日常观察的原位交互；最后，Omnisight

拟引入实测眼动驱动光束对齐，以眼动和脑电区分观察与操作意图，并通过光学选择与蓝牙会话的分层设计提升连接连续性。三项工作均按照“注意力—对象绑定—意图确认—会话与动作—实验评价—能力边界”的顺序分析，并以目标错选、误触发与漏检、时延、会话恢复、功耗和用户负担共同检验收益。

3.2 本文主要工作及进展

本文围绕注意力如何转化为可靠、可执行的定向交互，开展以下三项工作。

RetroAR：基于手机指向的可见光非接触定向交互系统。 RetroAR 面向移动增强现实中的非接触定向交互[40]，利用手机闪光灯、逆反射标签 ViTag 与后置摄像头构成同向光学链路，使用户在指向物体的同时完成目标发现与局部信息读取。其核心贡献包括：

- 提出面向商用手机的可见光定向交互机制，以光束方向和摄像头视场共同约束候选对象，将手机指向这一间接注意力转化为物理目标绑定；
- 设计消息级动态兴趣区、快速凸包检测、自适应时空混合解码与六自由度位姿估计，使系统能够应对手机运动、视角变化和复杂光学背景；
- 完成原型和用户研究评估：系统最远可在约 4m 距离和约 100° 视角下工作，位姿估计误差低至约 1cm 和 4.7°，交互时间相较 Wi-Fi 基线减少两倍以上。

该工作验证了“所指即所控”的可行性，但仍要求用户举起并持续对准手机，使用的是设备方向而非真实视线，由此引出佩戴式观察方向能否替代手持指向的问题。

EchoSight：基于智能眼镜的双向近红外直观交互系统。 EchoSight 将定向交互入口迁移到智能眼镜[41]，由眼镜端 SightReader 与对象端 EchoTag 建立双向近红外光学链路，使用户在观察目标时获取身份和状态并发送控制数据。其核心贡献包括：

- 提出佩戴式原位双向交互架构，把对象选择、身份获取和命令传输放入同一现场通道，减少举机、扫码和预先无线连接步骤；
- 设计双元件互补光学前端、双波段差分信号、对齐检测与按需唤醒机制，抑制环境光干扰和非目标对象响应；
- 完成房间尺度原型和用户研究评估：系统最远可在约 5m 距离和约 120° 视角下工作；在 12 名参与者的实验中，相较二维码扫描和语音控制至少降低五倍交互延迟，并减小主观负担。

该工作验证了“所看即所控”在所设任务中的效率优势，但眼镜机身光轴只近似观察方向，不能测量真实注视点，也无法区分日常观看与操作意图；遮挡和转头还可能中断全光会话。

Omnisight: 眼、脑联合的注意力驱动意图交互系统。 Omnisight 拟进一步解决设备方向与真实视线的偏差、“看向”与“想操作”的二义性，以及全光链路难以持续维持会话的问题。计划开展的核心工作包括：

- 在眼镜端测量眼动，标定眼动、头部姿态与光束坐标之间的变换，并驱动可调光学发射单元主动追随关注目标；
- 同步采集眼动与凝胶电极脑电，比较仅眼动、仅脑电、多模态融合以及眼动加显式确认，检验 EEG 对降低误触发是否具有稳定的增量价值；
- 以定向光完成目标发现和身份确认，再将授权物体绑定到蓝牙身份，由蓝牙维持反馈与后续会话，并设计超时、切换和重绑定机制；
- 通过固定/可调光束对照、多模态消融和完整任务用户研究，评价目标错选、误触发与漏检、决策及端到端时延、会话恢复、功耗和佩戴负担。

目前 Omnisight 的总体架构和实验问题已经明确，眼镜原型、脑电同步、融合模型及混合链路协议仍待实现和评估。若 EEG 无法提供足以覆盖采集与佩戴成本的稳定收益，将采用眼动加显式确认作为备选路线，并把这一适用边界作为研究结论。

第四章 研究计划

4.1 论文提纲

计划中最终完成的学位论文将分为五章。全文以“注意力如何转化为可靠、可执行的定向交互”为主线，按照注意力由间接到直接、系统能力由目标选择到意图判别的顺序展开三项工作。各章内容安排如下：

第一章绪论：提出人机共生环境中的多对象定向交互问题，分析从目标发现、对象绑定、意图确认到会话维持与动作反馈的关键挑战；在此基础上，建立注意力外化、注意力对齐和意图判别逐级深入的研究框架，并概述本文的研究内容与主要贡献。

第二章基于手机指向的移动增强现实定向交互系统：介绍 RetroAR 的设计、实现与评估。该章研究如何将用户的手机指向转化为可计算的空间关注，利用可见光逆反射标签在同一光学链路中完成目标发现、身份读取与空间定位，并通过动态兴趣区、时空混合解码和六自由度位姿估计实现“所指即所控”。

第三章基于眼镜观察方向的原位双向交互系统：介绍 EchoSight 的设计、实现与评估。该章将定向交互入口由手持设备迁移至智能眼镜，研究双元件、双波段近红外光路和对齐检测机制，实现在无需预注册和额外无线配对条件下的原位双向交互，并分析由“所指即所控”向“所看即所控”推进所带来的自然性收益及其能力边界。

第四章眼、脑联合的注意力驱动意图交互系统：介绍 Omnisight 的设计、实现与评估。该章在 EchoSight 的基础上引入实测眼动，驱动可调光学发射单元主动对齐目标；进一步利用脑电辅助区分日常观看与主动操作，并研究定向光学选择通道与蓝牙持续会话通道之间的可验证绑定。该章将通过固定与可调光束对照、多模态消融和完整任务用户研究，检验“所思即所控”的可行性、实际收益与适用边界。

第五章总结与展望：总结手机指向、眼镜观察方向以及眼动与脑电三类注意力在对象选择、意图确认和持续交互中的递进关系，归纳注意力驱动定向交互的设计原则与适用条件，并讨论其在多对象人机共生环境中的后续研究方向。

4.2 时间进度安排

在前述三项工作中，RetroAR 与 EchoSight 的系统设计、原型实现和实验评估已经完成；Omnisight 的总体架构与实验问题已经明确，但眼镜原型、眼动与脑电同步、融合模型、混合链路协议及系统评估仍待完成。围绕 Omnisight 研究和学位论文撰写，计划设置以下四个时间节点：

1. 在 2026 年 10 月 31 日以前，完成眼动追踪、可调光学发射和脑电采集模块的接入，建立统一时间戳与基础标定流程，完成眼动、头部姿态和光束坐标之间的转换，并记录系统同步误差与初步对齐误差。
2. 在 2026 年 12 月 30 日以前，完成观看与主动操作任务范式、脑电预处理和离线分类基线，明确跨用户验证方法；同时完成光学目标标识与蓝牙设备身份的可验证绑定，以及目标切换、会话超时、重绑定和恢复机制，形成可执行的端到端 Omnisight 原型。
3. 在 2027 年 2 月 31 日以前，完成固定与可调光束对照、眼动与脑电多模态消融及完整任务用户研究，系统评估目标错选率、误触发率、漏检率、决策与端到端时延、会话恢复时间、功耗和用户负担；在复核实验结果与系统边界的基础上，完成 Omnisight 研究论文的撰写与投稿。
4. 在 2027 年 3 月 31 日以前，整合 RetroAR、EchoSight 与 Omnisight 三项工作，完成学位论文的撰写、修改和答辩准备。

参考文献

- [1] 工业和信息化部等十五部门. “十四五”机器人产业发展规划. 2021-12-21. https://www.miit.gov.cn/zwgk/zcwj/wjfb/tz/art/2021/art_14c785d5a1124f75900363a0f45d9bbe.html, accessed on 2026-09-20.
- [2] 国务院. 关于深入实施“人工智能+”行动的意见. 2025-08-21. https://www.gov.cn/zhengce/content/202508/content_7037861.htm, accessed on 2026-09-20.
- [3] 国家发展和改革委员会高技术司. 人工智能赋能社会治理：人机共生的全新图景. 2025-08-26. https://www.ndrc.gov.cn/xxgk/jd/jd/202508/t20250826_1400071.html, accessed on 2026-09-20.
- [4] The White House. *America's AI Action Plan*. 2025-07. <https://www.whitehouse.gov/wp-content/uploads/2025/07/Americas-AI-Action-Plan.pdf>, accessed on 2026-09-20.
- [5] European Commission. *Apply AI Strategy*. 2025-10-08. <https://digital-strategy.ec.europa.eu/en/policies/apply-ai>, accessed on 2026-09-20.
- [6] 国家税务总局办公厅. 税收数据显示：我国具身智能产业总体发展向好. 2026-06-30. <https://www.chinatax.gov.cn/chinatax/n810219/n810724/c5250672/content.html>, accessed on 2026-09-20.
- [7] 魏梦佳 and 阳娜. 中国具身智能迎来规模化应用关键窗口期. 2026-08-24. https://www.digitalchina.gov.cn/2026/xwzx/szcx/202608/t20260824_5362593.htm, accessed on 2026-09-20.
- [8] BMW Group. *First Humanoid Robot Introduced in Plant Leipzig*. 2026-03-09. <https://www.bmwgroup.com/en/news/general/2026/humanoid-robot-in-leipzig.html>, accessed on 2026-09-20.
- [9] Scarlett Evans. *Physical AI's Challenge: Making Humanoid Robots Work in the Real World*. 2026-09-15. <https://www.techtarget.com/ai/news/366650269/Physical-AIs-challenge-Making-humanoid-robots-work-in-the-real-world>, accessed on 2026-09-20.
- [10] Michael I. Posner. “Orienting of Attention”. *Quarterly Journal of Experimental Psychology*, **1980**, 32(1): 3–25.
- [11] Richard A. Bolt. ““Put-That-There”: Voice and Gesture at the Graphics Interface”. In: *Proceedings of the 7th Annual Conference on Computer Graphics and Interactive Techniques*. **1980**: 262–270.
- [12] Robert J. K. Jacob. “What You Look At Is What You Get: Eye Movement-Based Interaction Techniques”. In: *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*. **1990**: 11–18.
- [13] David Garlan, Daniel P. Siewiorek, Asim Smailagic et al. “Project Aura: Toward Distraction-Free Pervasive Computing”. *IEEE Pervasive Computing*, **2002**, 1(2): 22–31.
- [14] Roel Vertegaal. “Attentive User Interfaces”. *Communications of the ACM*, **2003**, 46(3): 30–33.

-
- [15] Jeffrey S. Shell, Roel Vertegaal, Aadil Mamuji *et al.* “*EyePliances and EyeReason: Using Attention to Drive Interactions with Ubiquitous Appliances*”. In: *Adjunct Proceedings of the 16th Annual ACM Symposium on User Interface Software and Technology*. **2003**. <https://uist.hosting.acm.org/archive/adjunct/2003/pdf/demos/d12-shell.pdf>, accessed on 2026-09-20.
- [16] Mihai Bâce, Teemu Leppänen, Argenis Ramirez Gomez *et al.* “*ubiGaze: Ubiquitous Augmented Reality Messaging Using Gaze Gestures*”. In: *SIGGRAPH ASIA 2016 Mobile Graphics and Interactive Applications*. **2016**.
- [17] Ken Pfeuffer, Benedikt Mayer, Diako Mardanbegi *et al.* “*Gaze + Pinch Interaction in Virtual Reality*”. In: *Proceedings of the 5th Symposium on Spatial User Interaction*. **2017**: 99–108.
- [18] Adrian A. de Freitas, Michael Nebeling, Xiang Anthony Chen *et al.* “*Snap-To-It: A User-Inspired Platform for Opportunistic Device Interactions*”. In: *Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems*. **2016**: 5909–5920.
- [19] Ke Huo, Yuanzhi Cao, Sang Ho Yoon *et al.* “*Scenariot: Spatially Mapping Smart Things within Augmented Reality Scenes*”. In: *Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems*. **2018**: 1–13.
- [20] Tengxiang Zhang, Zitong Lan, Chenren Xu *et al.* “*BLEselect: Gestural IoT Device Selection via Bluetooth Angle of Arrival Estimation from Smart Glasses*”. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, **2023**, 6(4).
- [21] Ethan Wilson, Naveen Sendhilnathan, Charlie S. Burlingham *et al.* “*Eye Gaze as a Signal for Conveying User Attention in Contextual AI Systems*”. In: *Proceedings of the 2025 Symposium on Eye Tracking Research and Applications*. **2025**.
- [22] Microsoft. *Gaze and Dwell*. 2022-07-19. <https://learn.microsoft.com/en-us/windows/mixed-reality/design/gaze-and-dwell>, accessed on 2026-09-20.
- [23] Apple. *Get Started with visionOS*. <https://developer.apple.com/visionos/get-started/>, accessed on 2026-09-20.
- [24] Anna Maria Feit, Shane Williams, Arturo Toledo *et al.* “*Toward Everyday Gaze Input: Accuracy and Precision of Eye Tracking and Implications for Design*”. In: *Proceedings of the 2017 CHI Conference on Human Factors in Computing Systems*. **2017**: 1118–1130.
- [25] Weichen Liu and Gianna Andrade. “*Evaluation of Gaze-to-Object Mapping Algorithms for Use in “Real-World” Translatable Neuropsychological Paradigms*”. *Psychology & Neuroscience*, **2023**, 16(4): 339–348.
- [26] Ken Pfeuffer, Hans Gellersen and Mar Gonzalez-Franco. “*Design Principles and Challenges for Gaze + Pinch Interaction in XR*”. *IEEE Computer Graphics and Applications*, **2024**, 44(3): 74–81.
- [27] Hirokazu Kato and Mark Billinghurst. “*Marker Tracking and HMD Calibration for a Video-Based Augmented Reality Conferencing System*”. In: *Proceedings of the 2nd IEEE and ACM International Workshop on Augmented Reality*. **1999**: 85–94.
- [28] Hongshen Ma and Joseph A. Paradiso. “*The FindIT Flashlight: Responsive Tagging Based on Optically Triggered Microprocessor Wakeup*”. In: *UbiComp 2002: Ubiquitous Computing*. **2002**: 160–167.

- [29] Jackie Junrui Yang and James A Landay. “InfoLED: Augmenting LED Indicator Lights for Device Positioning and Communication”. In: *Proceedings of the ACM Symposium on User Interface Software and Technology*. **2019**.
- [30] Karan Ahuja, Sujeath Paredy, Robert Xiao *et al.* “LightAnchors: Appropriating Point Lights for Spatially-Anchored Augmented Reality Interfaces”. In: *Proceedings of the ACM Symposium on User Interface Software and Technology*. **2019**: 189–196.
- [31] IEEE Standards Association. *IEEE 802.15.7-2011: Short-Range Wireless Optical Communication Using Visible Light*. 2011-06-16. <https://standards.ieee.org/ieee/802.15.7/5154/>, accessed on 2026-09-20.
- [32] Harald Haas, Liang Yin, Yunlu Wang *et al.* “What Is LiFi?” *Journal of Lightwave Technology*, **2016**, 34(6): 1533–1544.
- [33] Signify. *Signify Launches Trulifi*. 2019-06-19. <https://www.signify.com/global/our-company/news/press-releases/2019/20190619-signify-launches-trulifi>, accessed on 2026-09-20.
- [34] IEEE 802.11 Working Group. *IEEE Std 802.11bb-2023: Light Communications*. 2023-11-10. <https://grouper.ieee.org/groups/802/11/overview.html>, accessed on 2026-09-20.
- [35] Jiangtao Li, Ailin Liu, Guobin Shen *et al.* “Retro-VLC: Enabling Battery-Free Duplex Visible Light Communication for Mobile and IoT Applications”. In: *Proceedings of the 16th International Workshop on Mobile Computing Systems and Applications*. **2015**: 21–26.
- [36] Xuhai Xu, Y Shen, J Yang *et al.* “PassiveVLC: Enabling Practical Visible Light Backscatter Communication for Battery-free IoT Applications”. In: *Proceedings of ACM MobiCom*. **2017**.
- [37] Y Wu, P Wang, K Xu *et al.* “TurboBoosting Visible Light Backscatter Communication”. In: *Proceedings of ACM SIGCOMM*. **2020**.
- [38] Xiping Wu, Mohammad Dehghani Soltani, Lai Zhou *et al.* “Hybrid LiFi and WiFi Networks: A Survey”. *IEEE Communications Surveys & Tutorials*, **2021**, 23(2): 1398–1420.
- [39] S D Perli, N Ahmed and D Katabi. “PixNet: Interference-free Wireless Links Using LCD-camera Pairs”. In: *Proceedings of ACM MobiCom*. **2010**.
- [40] 李景聿, 陈拓朝, 李明哲 *et al.* “基于可见光逆反射通信的移动增强现实定向交互”. *电子学报*.
- [41] Jingyu Li, Qingwen Yang, Kenuo Xu *et al.* “EchoSight: Streamlining Bidirectional Virtual-physical Interaction with In-situ Optical Tethering”. In: *Proceedings of the CHI Conference on Human Factors in Computing Systems*. **2025**.
- [42] Daniel Wagner, Gerhard Reitmayr, Alessandro Mulloni *et al.* “Real-Time Detection and Tracking for Augmented Reality on Mobile Phones”. *IEEE Transactions on Visualization and Computer Graphics*, **2010**, 16(3): 355–368.
- [43] Adrian A. de Freitas, Michael Nebeling, Akshaye Shreenithi Kirupa Karrie Ranithangam *et al.* “Bluewave: Enabling Opportunistic Context Sharing via Bluetooth Device Names”. In: *Proceedings of the 8th ACM SIGCHI Symposium on Engineering Interactive Computing Systems*. **2016**: 38–49.

-
- [44] Maruchi Kim, Antonio Glenn, Bandhav Veluri *et al.* “*IRIS: Wireless Ring for Vision-Based Smart Home Interaction*”. In: *Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology*. **2024**.
 - [45] Fengyuan Zhu and Tovi Grossman. “*BISHARE: Exploring Bidirectional Interactions Between Smartphones and Head-Mounted Augmented Reality*”. In: *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*. **2020**: 1–14.
 - [46] Hiroki Kaimoto, Kyzyl Monteiro, Mehrad Faridan *et al.* “*Sketched Reality: Sketching Bi-Directional Interactions Between Virtual and Physical Worlds with AR and Actuated Tangible UI*”. In: *Proceedings of the 35th Annual ACM Symposium on User Interface Software and Technology*. **2022**.
 - [47] Zhengzhe Zhu, Ziyi Liu, Tianyi Wang *et al.* “*MechARspace: An Authoring System Enabling Bidirectional Binding of Augmented Reality with Toys in Real-Time*”. In: *Proceedings of the 35th Annual ACM Symposium on User Interface Software and Technology*. **2022**.
 - [48] Reza Abiri, Soheil Borhani, Eric W. Sellers *et al.* “*EEG-Based Brain-Computer Interfaces (BCIs): A Survey of Recent Studies on Signal Sensing Technologies and Computational Intelligence Approaches and Their Applications*”. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, **2021**, 18(5): 1645–1666.
 - [49] Lawrence A. Farwell and Emanuel Donchin. “*Talking off the Top of Your Head: Toward a Mental Prosthesis Utilizing Event-Related Brain Potentials*”. *Electroencephalography and Clinical Neurophysiology*, **1988**, 70(6): 510–523.
 - [50] Shangkai Gao, Yijun Wang, Xiaorong Gao *et al.* “*Visual and Auditory Brain–Computer Interfaces*”. *IEEE Transactions on Biomedical Engineering*, **2014**, 61(5): 1436–1447.