



北京大学

博士研究生学位论文开题报告

题目： 面向人机共生的注意力驱动定
向交互技术研究

姓 名： 李景聿
学 号： 2301111877
院 系： 计算机学院
专 业： 计算机系统结构
研究方向： 智能无线网络与移动计算
导 师： 许辰人长聘副教授

二〇二六年九月

摘要

随着具身智能与泛在智能物体逐步进入生产和生活环境，人机关系正由人使用单一设备完成离散任务，转向人与多个具身智能体共享物理情境、持续感知彼此状态并动态协作的人机共生。在这一过程中，交互对象、任务进程与环境状态均可能实时变化，用户因而不仅需要“操作设备”，还需要在多个共处对象之间迅速辨认当前目标、自然地表达交互意图，并将指令准确地作用于特定对象。以协同工厂为例，操作人员可能需要在机械臂、移动机器人和智能工位之间连续切换，查看某一对象的状态并随即下达指令，而不应反复退出当前任务以搜索设备。由此，面向多对象的、符合人类空间认知习惯的直观定向交互，成为人机共生时代的新需求。

然而，现有交互方式难以满足这一需求。二维码扫描、设备列表检索和无线配对等方式忽视了指向、朝向与注视中已经包含的空间关注信息；即使用户已明确关注某一对象，仍需在界面中重新查找、确认并连接设备，使物理对象选择、数字身份识别、连接建立与动作执行相互割裂。究其根因，现有系统无法将人的自然注意力直接转化为可靠的对象绑定，只能借助额外的显式步骤恢复交互过程中丢失的注意力信息，因而增加了多对象切换的时间、操作与认知负担。因此，如何捕捉并利用可测量的注意力，在不增加额外操作的前提下准确绑定交互对象，是实现直观定向交互的核心问题。本文围绕如何挖掘、利用人真实注意力并可靠地转化为高效、精准的定向交互这一问题展开研究。通过对人类注意力信息由浅入深的挖掘和利用，形成“所指即所控—所看即所控—所思即所控”的三种定向交互模式，旨在为未来人机共生提供一个新的交互模式解决方案。具体来说，主要研究工作如下：

(1) 针对广泛普及的手机等手持终端，本文提出基于指向的非接触定向交互系统 **RetroAR**。本文首先发现，手机指向所携带的用户位置和方向信息可由可见光的定向传播特性自然保留。基于此，设计了面向商用手机的可见光定向交互机制：用户以手机闪光灯照射逆反射标签，标签调制反射光并由手机后置摄像头接收，无须检索和连接无线设备。为兼顾数据通信与空间锚定，本文进一步设计动态光标签 **ViTag**，并结合消息级动态兴趣区、快速凸包检测和自适应时空混合编解码，使系统在手机运动、视角变化和复杂光学背景下稳定读取标签并估计六自由度位姿。系统评估表明，**RetroAR** 最远可在约 4m 距离和约 100° 视角下工作；用户研究表明，其交互开销相比传统 Wi-Fi 扫码方案降低 50%，且交互负担更小。**RetroAR** 验证了光学链路利用“指向”提升定向交互效率的可行性，为“所指即所控”提供系统依据；

(2) 针对快速普及的 AR 眼镜终端，本文提出基于互补红外光学通信的定向交互

系统 EchoSight。本文发现，相较于需要主动抬起并对准的手持设备，眼镜方向能够自然贴近用户的观察方向，而红外光束的定向特性可以保留用户注意力指向性，使目标识别与控制一步完成：用户看向目标并做出手势后，眼镜端 SightReader 发射调制红外光，对象端 EchoTag 接收指令并调制反射光，回送身份与状态信息，无须预先注册或建立无线连接。本文进一步设计双路互补光学前端，结合双波段差分信号、对准检测和按需唤醒机制，抑制环境光干扰与非目标响应，实现低时延双向通信。系统评估表明，EchoSight 最远可在约 5m 距离和约 120° 视角下工作；用户研究表明，其交互效率相比二维码扫描和语音控制方案至少提升5倍，且主观负担更低、交互流畅性更好。EchoSight 验证了“视线”比“指向”承载更直观的注意力信息，为“所看即所控”提供系统依据；

（3）针对未来小型化、多模态的新式穿戴设备，本文拟提出利用眼动捕获注意力并结合脑电解码识别意图的定向交互系统 Omnisight。本文首先观察到，用户的眼睛注视朝向和眼镜朝向往往不对齐，且注视方向真正代表了其注意力落点；基于此，设计了由眼动驱动的“物理空间三维鼠标指针”：在AR眼镜上集成基于双目相机的眼动追踪模块，并设计光学云台实现LED波束转向，使光束主动追随用户的真实视线并对准关注目标。与此同时，本文进一步引入基于水凝胶电极的脑电意图识别机制，融合眼动和任务相关脑电信息，区分“看向但不操作”与“主动选择并执行”，以减少因纯注视无交互意图所带来的误操作；Omnisight 的研究旨在探索从“方向近似注意”到“眼动对齐+意图判别”的可行路径，为“所思即所控”提供待验证的系统方案。

关键词：具身智能，人机共生，注意力驱动，定向交互，眼动追踪，脑电意图解码

Attention-driven Directional Interaction for Human–Machine Symbiosis

Jingyu Li (Computer Architecture)

Directed by Prof. Chenren Xu

ABSTRACT

As embodied intelligence and ubiquitous intelligent objects increasingly enter production and everyday environments, the relationship between humans and machines is shifting from the use of a single device for discrete tasks toward human–machine symbiosis, in which people and multiple embodied agents share a physical context, continuously perceive one another’s states, and collaborate dynamically. In this setting, interaction targets, task progress, and environmental conditions may all change in real time. Users therefore need not only to operate devices, but also to rapidly identify the intended target among multiple co-located objects, express interaction intent naturally, and direct commands accurately to a specific object. In a collaborative factory, for example, an operator may need to switch continuously among a robotic arm, a mobile robot, and an intelligent workstation, checking the status of one object and immediately issuing a command without repeatedly leaving the current task to search for devices. Intuitive directional interaction that supports multiple objects and conforms to human spatial cognition has thus become a new requirement in the era of human–machine symbiosis.

Existing interaction methods, however, struggle to meet this requirement. QR-code scanning, device-list search, and wireless pairing overlook the spatial focus already conveyed by pointing, orientation, and gaze. Even after users have clearly attended to an object, they must still locate, confirm, and connect to the device again through an interface, separating physical-object selection, digital-identity recognition, connection establishment, and action execution. The fundamental reason is that existing systems cannot directly transform natural human attention into reliable object binding. Instead, they rely on additional explicit steps to recover attention information lost during interaction, thereby increasing the temporal, physical, and cognitive costs of switching among multiple objects. Capturing and exploiting measurable attention to bind an interaction target accurately without additional operations is therefore a central challenge in realizing intuitive directional interaction.

This dissertation investigates **how to uncover and exploit genuine human attention and reliably transform it into efficient and accurate directional interaction**. By progressively exploring and utilizing human attention, it develops three directional interaction paradigms: **“point to control, look to control, and intend to control.”** The goal is to provide a new interaction paradigm for future human–machine symbiosis. The main research contributions are as follows.

(1) For widely used handheld devices such as smartphones, this dissertation presents RetroAR, a pointing-based contactless directional interaction system. It first observes that the user’s position and orientation conveyed by smartphone pointing can be naturally preserved by the directional propagation of visible light. Based on this observation, it designs a visible-light directional interaction mechanism for commodity smartphones: the user illuminates a retroreflective tag with the smartphone flashlight, while the tag modulates the reflected light and the rear camera receives it, eliminating the need to search for and connect to wireless devices. To support both data communication and spatial anchoring, this dissertation further designs the dynamic optical tag ViTag and combines a message-level dynamic region of interest, fast convex-hull detection, and adaptive spatiotemporal hybrid coding and decoding. These techniques enable the system to read tags reliably and estimate six-degree-of-freedom poses under smartphone motion, viewpoint changes, and complex optical backgrounds. System evaluations show that RetroAR operates at distances of up to approximately 4m and viewing angles of up to approximately 100°. A user study shows that it reduces interaction overhead by 50% compared with a conventional Wi-Fi and QR-code-based approach, while imposing a lower interaction burden. RetroAR demonstrates the feasibility of using an optical link to improve directional interaction efficiency through pointing, providing a system-level basis for “point to control.”

(2) For the rapidly growing class of augmented-reality glasses, this dissertation presents EchoSight, a directional interaction system based on complementary infrared optical communication. Compared with handheld devices that must be actively raised and aimed, the orientation of glasses more naturally follows the user’s viewing direction, while the directionality of an infrared beam preserves the direction of the user’s attention, allowing target identification and control to be completed in a single step. After the user looks at a target and performs a gesture, the glasses-mounted SightReader emits modulated infrared light; the object-mounted EchoTag receives the command, modulates the reflected light, and returns identity and status information without preregistration or a wireless connection. This dissertation further designs

a dual-path complementary optical front end and combines dual-band differential signaling, alignment detection, and on-demand wake-up to suppress ambient-light interference and responses from non-target objects, thereby enabling low-latency bidirectional communication. System evaluations show that EchoSight operates at distances of up to approximately 5 m and viewing angles of up to approximately 120°. A user study shows that its interaction efficiency is at least five times that of QR-code scanning and voice-control approaches, with a lower subjective workload and greater interaction fluency. EchoSight demonstrates that looking conveys attention more intuitively than pointing, providing a system-level basis for “look to control.”

(3) For future miniaturized and multimodal wearable devices, this dissertation proposes Omnisight, a directional interaction system that captures attention through eye tracking and recognizes intent through EEG decoding. It first observes that the direction of a user’s gaze is often misaligned with the orientation of the glasses and that gaze direction more faithfully indicates where the user’s attention is focused. Based on this observation, it designs an eye-tracking-driven “three-dimensional mouse pointer in physical space.” A binocular-camera-based eye-tracking module is integrated into AR glasses, and an optical gimbal steers an LED beam so that it actively follows the user’s actual line of sight and aligns with the attended target. Meanwhile, this dissertation introduces an EEG-based intent-recognition mechanism using hydrogel electrodes. By combining eye-tracking data with task-related EEG signals, the mechanism distinguishes between “looking without acting” and “actively selecting and executing,” thereby reducing unintended operations caused by gaze without interaction intent. The Omnisight study aims to explore a feasible path from approximating attention through device orientation to aligning with gaze and discriminating intent, providing a system design to be validated for “intend to control.”

KEYWORDS: Embodied intelligence, Human–machine symbiosis, Attention-driven, Directional interaction, Eye tracking, EEG

目录

第一章 研究背景与挑战	1
1.1 具身智能与人机共生的发展与挑战	1
1.2 人机共生环境中注意力驱动的定向交互	4
1.3 面向定向交互的通信感知技术发展	6
第二章 研究现状	9
2.1 定向光学链路	9
2.2 注意力驱动的直观交互	12
2.3 基于眼动、脑电信号的意图识别	15
第三章 本文工作及当前进展	19
3.1 技术挑战	19
3.2 研究工作总览	20
3.3 RetroAR: 基于手机指向的可见光非接触定向交互系统	21
3.3.1 引言	21
3.3.2 研究背景	21
3.3.3 系统概述	22
3.3.4 系统设计	22
3.3.5 系统验证	25
3.3.6 用户实验	27
3.3.7 小结	28
3.4 EchoSight: 面向智能眼镜的双向近红外直观交互系统	30
3.4.1 引言	30
3.4.2 研究背景	31
3.4.3 系统概述	31
3.4.4 系统设计	32
3.4.5 系统验证	35
3.4.6 用户实验	37
3.4.7 小结	39
3.5 Omnisight: 眼脑联合的注意力驱动意图交互系统	41
3.5.1 引言	41

3.5.2	研究背景	42
3.5.3	系统概述	42
3.5.4	系统设计	42
3.5.5	系统验证	43
3.5.6	用户实验	43
3.5.7	小结	43
第四章	研究计划	45
4.1	论文提纲	45
4.2	时间进度安排	45
参考文献		47

第一章 研究背景与挑战

1.1 具身智能与人机共生的发展与挑战

人工智能正在由以数字内容处理为主的软件能力，进一步走向能够感知环境、理解任务并作用于物理世界的具身智能。机器人、智能汽车、可穿戴设备、智能家居和新型生产装备持续进入真实场景，使计算不再局限于屏幕之内，而是分布在具有不同形态、位置和功能的物理对象之中。由此，人与机器的关系也开始从“人使用单一工具”转向“人与多类智能体共享环境并协同完成任务”：机器不仅接收预先定义的指令，还会根据环境状态提供信息、提出建议乃至执行动作；人则需要在动态过程中理解机器状态、表达目标并保持必要的监督。

这一变化已成为全球人工智能竞争和产业政策的重要方向。我国《中华人民共和国国民经济和社会发展第十五个五年规划纲要》将机器人列为战略性新兴产业，将具身智能纳入未来产业重点领域，提出构建应用场景和生态体系、开展新技术新产品新场景大规模应用示范，推动其成为新的经济增长点^[1]；2025 年国务院发布《关于深入实施“人工智能+”行动的意见》，进一步提出推动人工智能与经济社会各领域广泛深度融合，加快形成人机协同、跨界融合、共创分享的智能经济和智能社会新形态^[2]，国家发展改革委随后将人机协作、人机交互和虚实融合概括为智能社会的重要特征，并提出面向人机共生布局新型智能基础设施^[3]。国际上，美国《人工智能行动计划》把自动驾驶、无人机和机器人列为人工智能作用于物理世界的重要形态，提出支持下一代制造并识别机器人制造的供应链挑战^[4]；欧盟“Apply AI”战略则把机器人、制造、交通和医疗列为重点领域，通过人工智能工厂、测试验证设施和监管沙盒推动技术由实验室走向市场，同时强调可信、安全和以人为本的应用^[5]。不同经济体在发展路径和治理方式上各有侧重，但共同表明，人工智能竞争已由模型和算力延伸到智能机器能否进入物理环境、与人协作并形成可持续的生产与服务能力。

政策推动正快速转化为全球产业投入和终端供给。在国内，国家税务总局数据显示，2026 年 1—5 月我国具身智能产业企业销售收入同比增长 22.4%，机器人本体与整机制造企业销售收入增长 30.1%，工业企业购进具身智能机器人的金额同比增长 2.3 倍^[6]；2026 世界机器人大会发布的信息显示，我国人形机器人整机产品已超过 400 款，上半年出货量超过 4 万台，机器人已在多个物流中心参与包裹分拣、在近百家药店承担药品拣选，并开始进入景区讲解、社区巡逻和商业服务等场景^[7]。在海外，宝马于 2026 年在德国莱比锡工厂启动人形机器人 AEON 的生产试点，使其参与高压电池装

配、零部件生产和物料配送；此前美国斯帕坦堡工厂的 Figure 02 已在十个月内参与超过 3 万辆汽车的生产^[8]。这些中外案例说明，具身智能正由样机展示迁移到真实生产与服务现场，机器也由隔离区域内的固定自动化设备逐步转向能够移动、感知并与工作人员共享作业空间的协作主体，相关发展趋势与场景落地之间的差距如图 1.1 所示。




图 1.1 具身产业发展速度与人机协作场景落地之间的差距

然而，终端数量和展示能力的增长，并不等于人机共生已经成熟。现有案例大多仍集中在物流搬运、部件取放和巡检等边界清晰的任务中，常以少量设备、限定工位或试点项目运行。即使在相对结构化的汽车工厂，宝马仍需先建立统一的数据与接口体系，并在部署过程中增设安全隔离设施、改善厂区 5G 覆盖，再将机器人逐步接入生产流程^[8]。面向开放环境的行业观察也指出，机器人虽然可以在演示中完成任务，但其速度和可靠性往往尚不足以直接进入工业部署；当不可预测的人进入环境后，机器还必须理解人的语言、手势、姿态和空间指代^[9]。

这一现状促使我们思考：当具身智能设备已经开始走进工厂、商场、社区和家庭，为什么自然、稳定的人机共生仍未成为普遍现实？表面上看，问题表现为机器灵巧性不足、续航有限或模型泛化能力不够；从人机系统的角度看，更深层的原因在于，当前技术主要解决“机器能否完成一个动作”，却尚未充分解决“人如何在复杂现场找到机器、让机器理解自己，并在多个对象之间建立可靠协作关系”。实验室中的一次成功执行通常具有预设目标、已知对象和受控环境，而真实共生场景中的目标、参与者与任务状态会持续变化，两者所需的系统能力并不相同。

首先，现实环境具有开放性和不确定性。物体位置、光照、遮挡和人员活动不断变化，同一指令在不同场景下可能对应不同对象与动作。机器需要把感知结果与物理实体、任务上下文和安全边界联系起来，而不能只复现训练数据中的动作序列。当感知置信度下降或环境发生变化时，系统还要知道何时暂停、请求帮助或把控制权交还给人。这使具身智能的规模化应用不只是模型泛化问题，也是现场状态能否被共同理解的问题。

其次，人机共生环境具有多对象和多主体特征。许多系统仍以“一名用户、一块屏幕、一台预先连接的设备”为基本假设，依靠应用程序、设备名称和菜单层级组织操作。当用户面对多台外观相似的机器人、显示器、传感器或家电时，必须先从网络列表中识别目标，再完成搜索、配对、选择和控制。人在物理空间中已经通过位置、朝向或注视表达了关注对象，数字系统却经常丢失这一信息，导致物理对象、数字身份和交互会话相互分离。

再次，具身智能直接作用于现实世界，交互错误会产生物理后果。系统若选错对象，指令可能被相邻设备执行；若把短暂观察误判为控制意图，又可能触发并非用户所愿的动作。为了规避风险，现有部署常通过隔离区、固定流程和专业人员监督限制机器行为，但这些措施也限制了机器与普通用户自然接触的范围。人机共生因此需要在效率与安全之间取得平衡：既不能让用户为每个简单动作经历冗长配置，也不能把模糊的方向、语音或注视直接解释为高风险命令。

由上述分析可见，人机共生的交互鸿沟集中体现在三个相互衔接的系统挑战上：一是动态场景中的目标解析，即在位置、遮挡、人员和任务状态持续变化时，从指向、朝向、注视与上下文等线索中判断用户当前关注的是哪一个现实对象，以及这种关注是否已经构成交互意图；二是物理对象与数字身份对齐，即在多台同类设备并存的环境中，将选中的现实实体可靠映射到唯一的设备身份与通信地址，避免物理选择与网络连接彼此脱节；三是意图确认与交互闭环，即根据操作风险决定何时执行、确认、暂停或交还控制，并在移动、遮挡和目标切换过程中持续向用户反馈对象、命令与执行状态。三者依次回答“用户要与谁交互”“系统实际连接的是谁”和“双方如何安全、连续地完成交互”，共同要求围绕同一现实对象建立清晰、低负担且可验证的人机关系。

综上，具身智能的政策支持、产业投入和终端供给正在全球范围内快速增长，但从可演示、可试点走向可普遍共生，仍存在明显的交互鸿沟。人机共生并不是简单增加机器数量，也不是让机器完全替代人，而是要求人能够自然表达目标，机器能够准确识别对象和意图，双方能够围绕同一任务持续交换状态并处理异常。要跨越这道“最后一公里”，需要从现场空间关系出发重新审视交互入口，使目标发现、身份确认、动作执行与结果反馈围绕同一现实对象连续展开。定向交互由此成为连接具身智能能力与人机共生体验的重要基础。

围绕这一问题，本文前期已经完成两项递进工作：**RetroAR** 利用手机指向与可见光逆反射链路，在同一过程中完成目标选择、身份读取和空间定位；**EchoSight** 进一步将交互入口迁移到 **AR** 眼镜，通过双向近红外链路支持面向目标的就地识别与控制。两项工作分别验证了“所指即所控”和“所见即所控”的可行性，也共同暴露出设备

朝向仍不能等同于精确视线、自然观察仍不能等同于操作意图等问题，由此构成本文继续研究注意目标对齐与意图判别的基础。

1.2 人机共生环境中注意力驱动的定向交互

人机共生环境中的交互具有明确的对象性。用户并不是抽象地向整个环境发出命令，而是在特定时刻希望查看、询问或控制某一个现实对象，例如眼前的机械臂、医疗设备或灯具。当可交互对象由一块屏幕扩展为散布在空间中的大量机器，系统必须先于具体命令回答“用户要与哪一个对象交互”。本文所称的**定向交互**，即利用用户、交互设备与环境目标之间的空间方向关系，将人的指向映射到特定物理对象，并围绕该对象完成发现、身份确认、命令执行与结果反馈。“定向”既表示人的行为具有空间目标，也要求后续信息仍抵达这个目标，而不是在连接阶段退化为对设备列表的搜索。

人的注意力为方向提供了自然线索。人在准备使用物体前，通常会靠近、转头、注视或伸手指向它。不过，心理关注也可以在眼球不转动时发生隐蔽转移，因此注意力并不等同于单一传感器读数，视线只是重要但不完备的观测量^[10]。本文所称的注意力驱动交互，是指系统利用指向、头向、视线、手部动作和任务上下文估计用户关注的对象，并据此调节目标选择与交互流程；注意力驱动的定向交互则进一步把“用户关注哪里”转化为“系统应与哪一个现实对象建立交互”。其目的不是用眼睛替代鼠标，而是利用人已经自然表达的空间关注，减少重复搜索、命名和配对。

定向交互的发展始于对自然指代行为的数字化。1980年，麻省理工学院的“Put-That-There”系统将手势指向与语音结合，由方向回答“哪个对象和位置”，由语音表达动作^[11]。1990年，Jacob将眼动用于界面目标选择，同时指出眼睛既承担观察任务，又可能被解释为控制命令，从而产生“米达斯接触”问题^[12]。进入普适计算阶段，研究重点由操作一台计算机转向管理多设备环境中的注意力。卡内基梅隆大学2002年提出Project Aura，将人的注意力视为普适计算中最稀缺的资源，通过感知用户任务与可用设备减少配置和迁移造成的打断^[13]；随后形成的注意用户界面主张系统根据自己处于注意力前景还是背景决定何时响应^[14]。EyePliances给出了现实家电实例：电视在无人观看时暂停，AuraLamp只有在用户看向它时才接受语音命令^[15]。这些工作确立了“以方向确定目标、以其他线索确认操作”的基本范式。

移动计算、增强现实和可穿戴感知进一步把这一范式带入三维空间。ubiGaze利用头戴眼动设备把凝视手势附着到真实物体^[16]，Gaze+Pinch则以凝视指定目标、以捏合手势确认和操纵，形成“眼睛选择、手部承诺”的多模态分工^[17]。面向物联网，Snap-To-It、Scenariot和BLEselect分别探索借助目标图像、增强现实空间映射和蓝牙

到达角选择现实设备^[18-20]。目前研究又开始把眼动、手势、场景视觉和历史行为结合，用注意力帮助情境智能体理解用户任务。2025 年的研究表明，将此前的物体注视轨迹加入视觉语言模型上下文，可以改善模型对当前关注对象和下一步交互对象的判断^[21]。研究重心由瞬时“看向哪里”逐步扩展到持续的对象关联与任务情境。

注意力驱动交互也已进入商业空间计算平台。HoloLens 2 支持头部凝视、眼动凝视和凝视停留，适用于维修人员双手被工具占用且现场噪声不利于语音控制的场景^[22]；Apple Vision Pro 则把“看向对象并捏合手指”作为 visionOS 的主要间接交互方式^[23]。这些系统证明了注意力方向可以减少光标移动和远距离伸手，但其成熟体验主要建立在平台已知的窗口、三维模型和空间锚点之上。对于未预先建模的机械臂、家电或公共设施，系统仍需完成物体识别、数字身份关联和通信授权，才能把一次“看向”转化为现实操作。我们不禁思考：**当设备已经能够测量用户的指向、头向和视线，为什么注意力驱动定向交互仍未成为普遍能力？**例如，在装有两台同型号机械臂的车间中，眼镜可能测得用户正看向左侧机械臂，相机也识别出“机械臂”类别，但无线网络只返回两个相似的设备名称。系统仍不知道左侧实体对应哪个网络地址，也无法保证启动命令不会发给另一台机器。问题的关键因此不是能否获得一个方向，而是该方向能否被可靠地转化为正确对象、真实意图和一致的信息通道。

由方向线索确定注意目标仍存在较大不确定性。手持设备指向较明确，却要求用户举起并对准；头向便于持续获取，却只能粗略表示视野中心；眼动最接近视觉注意，但会受到标定误差、个体差异、设备滑移和自然扫视影响。日常条件下眼动的准确度和精密度会随用户、目标位置与设备状态明显变化^[24]；在三维场景中，角度误差还会随距离放大，同一视线附近可能存在相邻、同类或不同深度的多个物体。将测得的注视点映射为具有语义的注视物体，本身仍是尚未完全解决的问题^[25]。此外，用户查看灯具可能只是观察环境，并不意味着希望开灯；人在寻找零件或巡视设备时也会自然扫过大量对象。因此，目标解析不仅要融合指向、头向和视线以判断“关注什么”，还要结合动作与上下文判断当前关注是否足以启动交互。确定物理目标后，系统仍需将其与唯一的数字身份对齐。相机感知和 Wi-Fi、蓝牙发现分别回答“看见了什么”和“附近有什么设备”，却不能证明视野中的某个实体就是设备列表中的某个地址。在同型号设备密集部署、对象移动或遮挡的场景中，依据外观类别、设备名称或邻近关系建立映射都容易产生歧义。二维码、预注册数据库和空间锚点可以辅助关联，但会引入扫描、部署与维护开销，并可能随设备位置或环境布局变化而失效。物理对象与数字身份之间的断裂，使正确的空间选择仍可能转化为错误的网络连接。

建立连接也不意味着交互已经完成。若每次注视都触发命令，会产生严重误操作；若一律要求长时间停留、语音或手势确认，又会抵消注意力交互的效率。Gaze+Pinch

通过“凝视选择、手势确认”缓解米达斯接触，但眼手配合、目标切换和持续操纵仍缺乏统一规则^[26]。当用户移动、视线离开或链路短时中断时，系统还需要判断应保持会话、重新验证还是切换目标，并将执行状态和结果返回给用户，否则一次正确选择仍难形成可控的交互过程。

据此，注意力驱动定向交互可归纳为三项相互衔接的核心挑战：一是注意目标解析挑战，需要从带有噪声的多模态方向线索中确定用户关注的现实对象，并判断其是否进入交互状态；二是物理-数字身份对齐挑战，需要把选中的现实实体可靠映射到唯一的设备身份和网络地址；三是交互闭环保持挑战，需要根据操作风险设置确认机制，并在移动、遮挡和目标切换过程中维持命令、状态与反馈的一致性。三者依次回答“面向谁”“连接谁”和“如何持续交互”，共同将人的空间注意转化为可执行、可验证的现实操作。

综上，注意力驱动的定向交互已经由屏幕指向和凝视输入，发展到多设备注意力管理、空间计算与情境智能，但现有成果仍未完全贯通现实对象感知、身份确认和数据传输。要使“所指”“所见”可靠地转化为“所交互”，一方面需要**定向感知技术**提取注意方向并定位目标，另一方面需要**定向通信技术**利用空间约束核验目标身份、建立局部链路并返回反馈。光学技术同时具备成像感知、视距传播与波束空间约束能力，为统一注意方向、物理对象和信息通道提供了自然基础。

1.3 面向定向交互的通信感知技术发展

上一节指出，注意力驱动定向交互需要把人的注意方向绑定到物理对象，再将其转化为安全、连续的数字连接，即同时回答“目标在哪里”和“目标是谁”。视觉感知能够恢复对象的位置、类别和姿态，射频通信能够发现节点并维持连接，但二者的空间对象与网络身份并不天然对应。光学信号既可成像又可传输数据，并受光束方向、接收视场和遮挡关系约束，因此为统一注意方向、现实对象与信息通道提供了自然基础。

从实现机制看，光学通信通常采用强度调制与直接检测：发光器件以人眼难以察觉的速度改变光强，光电二极管或相机将接收光转换为电信号并恢复数据。发射光束越窄、接收视场越小，链路覆盖的空间范围越集中，不同方向上的对象也越容易分离。因此，光学用于定向交互的价值不仅在于频谱和速率，更在于通过物理传播范围缩小候选集合，使信息来源与用户面对的空间方向建立直接联系。

光学技术首先被用于**对象感知与空间锚定**。相机通过外观、二维码或人工标记识别目标，1999年的ARToolKit推动了视觉标记在增强现实注册中的应用^[27]；2002年的FindIT则使用手持光束唤醒匹配标签，使“照向哪里”直接决定“查询谁”^[28]。

InfoLED、LightAnchors 等系统进一步利用设备指示灯或场景点光源，将数字信息锚定到现实位置^[29,30]。这一路线建立了空间选择能力，但静态标记只能提供预存信息，识别结果仍需借助额外映射才能转化为控制链路。

高效 LED 与光电器件的普及推动技术由对象识别走向**双向光学通信**。2011 年，IEEE 802.15.7 定义了短距离可见光通信机制，LiFi 随后将单条光链路扩展为支持多用户接入和移动切换的无线网络^[31,32]。产业界也开始推动落地：Signify 于 2019 年推出 Trulifi 商用系统，2023 年发布的 IEEE 802.11bb 则将光通信纳入无线局域网标准体系^[33,34]。这些里程碑表明，光已由单向信息载体发展为可与现有网络协同的接入媒介。

然而，大量现实对象若采用主动光发射器回传，会带来持续供电、方向对准和硬件成本问题。由此形成的无源光学回传路线，使用主动读写器照射目标，以逆反射材料将入射光送回光源附近，并通过液晶等低功耗调制器在回波上编码身份与状态。Retro-VLC、PassiveVLC 和 TurboBoost 等工作逐步验证并提升了这类双向链路的距离、速率与环境适应性^[35–37]。当手机或眼镜指向目标时，窄光束先筛选候选对象，近原路返回的信号再确认其身份，使“指向哪个物体”与“数据来自哪个设备”在同一现场链路中得到验证，交互入口也由手持指向逐步走向头向和视线驱动。

方向性既是光学的优势，也是其限制。窄光束和小接收视场能够缩小候选范围、降低误绑定，却容易受到环境光、入射角、人体遮挡和用户移动影响，不适合独立承担长时间连接。射频链路则覆盖广、非视距能力强且基础设施成熟，但难以判断用户关注的是哪个现实对象。这种互补性推动技术路线走向**光学与射频混合**：定向光链路负责发现目标并读取身份、能力或临时凭据，Wi-Fi、蓝牙等射频网络随后承载可穿越短时遮挡的持续会话。已有 LiFi 与 Wi-Fi 混合网络也验证了局部光接入与广域无线覆盖的协同价值^[38]。

相较于单一媒介，混合路线可以在建立射频连接前利用空间方向缩小候选范围，并在选择完成后容忍转头、移动与暂时遮挡；同时，低功耗光标签只需交换身份、授权和少量状态，大数据传输与长期控制可以复用成熟射频设施。其关键不在于简单并列两条链路，而在于保证光学身份与射频地址一致，并合理设计遮挡后的保持、重新验证和目标切换机制，从而将第 1.2 节提出的注意目标解析、物理–数字身份对齐和交互闭环保持落实为完整交互流程。

基于上述脉络，本文以光学通信感知一体化作为注意方向与现实对象之间的入口，并探索光学与射频协同：首先利用手机指向和可见光逆反射实现对象选择与信息回传，继而将入口迁移到智能眼镜和近红外双向链路，进一步结合眼动追踪、可调光束与多模态意图判别，并在目标验证后转入可持续的无线会话，使交互由“所指”

走向“所见”与“所思”。

第二章 研究现状

2.1 定向光学链路

定向交互首先要求系统回答“当前数据究竟来自哪一个物体”。Wi-Fi、蓝牙等射频技术具有覆盖广和生态成熟的优势，但同一覆盖域中的多个设备共享发现空间，物理对象、网络地址与用户指向之间仍需额外映射；连续切换目标时，设备搜索和连接还会打断原本连续的空间行为。光学无线链路同时受到发射光束、接收视场和视距关系约束，其覆盖区域既定义信号可达范围，也保留用户与物体之间的空间关系。因此，光的方向性不仅是信道特征，也能够成为对象选择和身份绑定的交互资源。

早期系统已展示“以光选物”的基本可行性。FindIT Flashlight^[28]以手持光束触发微处理器标签，只有落在照射范围内的标签才响应，使“照向某物”直接参与候选筛选；不过，光链路主要负责触发，后续交互仍需其他接口。PixNet^[39]以LCD为发送端、摄像头为接收端，通过二维OFDM和几何校正图像中并行承载多个子信道。摄像头可以区分不同屏幕区域，但系统关注的是屏幕到相机的高速单向传输，并未将链路方向解释为用户对现实物体的选择。

上述工作证明光学接收天然保留空间来源，此后研究开始将其用于增强现实中的对象锚定。InfoLED^[29]复用设备已有的LED指示灯编码身份，并依据光源位置叠加对应界面；其部署对象广泛，但单个发光点提供的几何信息有限。LightAnchors^[30]进一步结合点光源识别、空间定位与AR内容呈现，如图2.1所示，用户可以指向灯光并访问锚定于该位置的内容。两项工作主要完成单向发现或显示；对象端主动发光需要额外能量，识别结果也常需再映射到无线控制通道，尚未形成从选择到命令执行的闭环。




图 2.1 LightAnchors系统通过手持指向，与数字化的LED建立定向光学通路

对象端持续发光的功耗限制促使研究者转向逆反射与光调制：读写器提供入射光，标签以逆反射材料回送光线，再驱动液晶调制器改变反射光强，从而避免主动产生光载波。Retro-VLC^[35] 以开关键控验证低功耗光学回传的可行性。PassiveVLC^[36] 针对液晶响应慢和反射信号弱进行器件与编码协同设计，使无电池标签形成实用双向链路；Wu et al.^[37] 则以多像素液晶、延迟叠加和偏振维度构造高阶调制，提高有限刷新率下的速率与距离。

如图 2.2 所示，这一阶段的核心贡献是证明被动标签也能返回身份或传感数据，使低功耗对象不必额外配置有源光发射器。相应研究主要把方向性视为提高空间复用率、减小干扰和降低功耗的信道条件，评价指标集中在误码率、速率、距离和视角。读写器通常面向单个既定标签建立链路，因此“光束照到了哪个标签”由实验布置预先确定，并未系统讨论光束方向与用户所选对象之间的语义对应。




图 2.2 PassiveVLC 无源光学链路原理图

随着标签规模增加，多个回传信号在同一接收器上叠加，研究重点又从单链路性能转向空间并发。RetroMUMIMO^[40] 利用制造公差和部署位置造成的液晶脉冲响应差异，在物理层并行解调多个上行，再以并发 MAC 减少碰撞、回退和轮询时延，将器件差异转化为多用户分离特征。2024 年，Ghiasi 与 Zuniga 同时利用偏振和颜色构造无源可见光 MIMO，使不同液晶单元形成可区分的子信道，其容量随调制单元数接近线性增长^[41]。这种方案主动扩展了光学维度，但也要求收发端协同配置颜色和偏振。

接收器件的进步进一步扩大了可并行观察的空间。Wang et al. 将事件相机与数字显微镜器件结合，只在像素亮度变化时输出事件，避免传统相机逐帧读取整幅图像的冗余，并行识别约两千个空间信道^[42]。该结果表明，光学空间分集能够显著提高密集场景下的吞吐与并发度，但其目标仍是尽可能多地恢复同时到达的信号。“同时读到多个标签”与“只绑定用户此刻关心的标签”分别对应通信容量和交互选择，前者并不

会自动给出后者所需的用户意图。

表 2.1 代表性定向光学工作的能力比较

代表工作	光学链路	空间信息来源	主要能力	交互链条缺口
FindIT	手持光束-标签	光束覆盖范围	定向触发	触发后仍需其他接口
PixNet	LCD-摄像头	图像像素位置	空间并行传输	不对应现实对象控制
InfoLED、LightAnchors	LED-摄像头	点光源位置	身份显示与空间锚定	以单向发现和显示为主
Retro-VLC、PassiveVLC	读写器-液晶标签	视距与逆反射方向	低功耗双向通信	目标通常由部署预先确定
RetroMUMIMO	读写器-多标签	标签脉冲差异	并发解调与接入	并发读取不等于用户选择
偏振/颜色 MIMO、事件相机方案	多维或多像素光信道	颜色、偏振或像素位置	扩展容量与并发度	缺少注意方向与身份绑定

表2.1将上述工作放在同一交互链条中比较。早期定向触发和光锚定保留了“信号来自哪里”，但返回信息或控制仍依赖另一条通道；逆反射系统补足低功耗回传，却通常假定读写器已经对准目标；多标签并发工作能够区分更多信号来源，却不判断哪一个来源对应用户此刻的关注对象。换言之，通信研究中的方向性主要服务于链路预算、空间复用和并发接入，交互研究中的方向性则需要同时承担候选筛选、实体身份核验和后续动作指向，两者的评价目标并不相同。

不同接收器架构进一步体现了通信性能与对象选择之间的取舍。光电二极管具有采样率高、灵敏度好和处理链简单等优势，适合接收弱小、快速变化的光信号，但单个器件缺乏空间分辨率；当多个标签同时落入接收视场时，它首先得到的是叠加波形，必须依靠协议、信号特征或多元件结构分离来源^[36,40]。普通摄像头能够把不同方位的光源投影到不同像素，从而同时获得数据和空间位置，却受帧率、曝光、运动模糊与计算开销限制^[29,39]。事件相机只报告亮度变化，在保留像素级空间分辨率的同时提高时间分辨率，但其优势仍主要体现为大规模信道读取，而非对用户关注对象的判断^[42]。

另一条研究路线把可见光与射频置于同一环境物联网架构中，使两种传播介质承担不同阶段的任务。正如图 2.3所示，BackVLC 较早提出由 LED 灯具向无电池标签发送可见光下行，同时由标签借助射频后向散射完成上行；标签还可从光照和射频载波中采集能量，从而利用光链路的局部覆盖和射频链路较灵活的回传能力^[43]。该工作验证了混合链路的基本可行性，但需要在灯具侧配置射频载波发生器，系统中的光覆盖区域、射频载波源与读取器也需要协同部署。在此基础上，Xie et al.设计的 LiBD 进一步使用可见光信号同时完成能量供给和后向散射调制控制，并以原型实验实现从 LED

到射频接收端的实时端到端传输^[44]。随后，Li2BC 在标签中加入低功耗微控制器及光信号放大、解调和缓存能力，使标签能够先接收并存储可见光指令，再据此控制射频后向散射，而不再局限于对输入光信号的即时转发^[45]。近期综述与原型研究据此将混合节点概括为仅采能、可见光中继和可见光控制等类型，并讨论其在环境物联网中的扩展方式^[46]。




图 2.3 光、射频混合链路原理示意图

综上，定向光学链路经历了从光触发和空间编码、低功耗逆反射到多标签并发的过程，既有研究已经能够“低功耗地传数据”和“并发地读标签”。然而，它们大多分别优化通信性能或空间显示，尚未让用户的自然方向稳定贯穿目标选择、身份核验、动作确认和状态反馈。本文据此关注如何把光学空间约束用于现实对象绑定，并明确其仍只是注意方向的代理，不能单独回答用户是否精确注视目标、是否准备执行操作以及链路中断后如何保持会话。下一节因此从通信链路转向完整交互过程，考察指向、头向与注视等注意力如何参与对象发现、选择、确认和反馈。

2.2 注意力驱动的直观交互

注意力驱动交互试图利用用户在日常行为中已经表达的位置、朝向、手部指向与注视，避免其在物理对象和数字界面之间重复说明目标。例如，用户面对并伸手指向一盏灯时，空间动作已经给出较强的候选范围；若系统仍要求在设备列表中查找名称或再次扫码，注意力便在交互入口处丢失。在多对象环境中，一个完整过程至少包括候选对象发现、物理对象与数字身份绑定、动作确认、命令传输和状态反馈。相关工作可据此分为三类：以视觉标记或外观发现对象，以无线测位和空间输入选择对象，以及在虚实界面中维持对象状态。它们的差异不只在所用模态，更在于注意力能够贯穿交互链条的哪一段，以及链条断开后需要用户补充多少显式操作。

第一类方法通过外部标记、物体外观或语义模型发现候选对象。二维码与人工视觉标签能够显式编码身份，并以角点等几何特征支持相机定位；它们识别结果明确、

实现成本较低，但要求标记处于视野内，且密集张贴会影响外观并把“看到目标”变成“寻找标签”。自然特征法直接跟踪纹理和轮廓，避免额外附着标记，却需要较多视觉计算，也容易受到弱纹理、相似外观、运动模糊、光照变化和遮挡影响^[47]。更重要的是，视觉识别得到的物体类别或实例名称未必就是可通信的设备身份，系统仍需查询数据库才能获得网络地址和控制接口。**Snap-To-It**^[18] 将这一查询过程包装为接近自然动作的交互：如图 2.4 所示，用户拍摄目标照片，系统在云端视觉数据库中匹配设备，再返回可用功能。它把列表搜索缩短为“拍到即选择”，但数据库需要预先采集目标及背景特征；环境或外观变化时，图像与设备记录之间的对应也可能失效。**Xu et al.** 将几何、语义和视觉语言特征融合进三维场景表示，支持在 AR 中以自然语言搜索现实对象^[48]。开放词汇模型由固定标签扩展到对类别、属性和空间关系的组合描述，能够覆盖更多未预先枚举的对象，但其输出仍主要是场景中的语义实体，不能天然给出设备地址、访问权限和实时状态。视觉方法越趋向开放场景理解，就越需要额外机制保证物理实例与数字身份的一致性。




图 2.4 外部标记发现方法原理示意

第二类方法不直接识别对象外观，而是利用无线测位与空间传感缩小候选范围。**Bluewave**^[49] 把 URL 等上下文信息写入蓝牙设备名称，使附近用户无须先建立连接便可获取服务入口。它降低了偶发交互的配对开销，但蓝牙广播仍覆盖一片区域，设备名称本身不能说明用户面对或指向的是哪一个物体，目标消歧仍需界面选择或其他空间线索。如图 2.5 所示，**Scenariot**^[19] 将超宽带定位与 SLAM 结合，先估计智能物体相对于用户的位置，再把该位置注册为 AR 场景中的可交互锚点。这样，用户能够在空间界面中发现并操作设备，但部署阶段需要为设备建立坐标，环境地图变化后也要维护物理位置与数字记录的对应。**BLEselect**^[20] 在智能眼镜上利用蓝牙天线阵列估计信号到达角，并将无线方向与用户手势指向联合起来，从多个广播设备中筛选目标。它保留了 BLE 发现和连接的生态优势，同时用方向信息减少列表选择；然而，射频传播中的多径和遮挡会扰动角度估计，空间指向与广播身份之间仍需算法关联。**IRIS**^[50] 进一步采用异构传感器互补的思路：无线指环提供手部运动和近距离无线线索，手机图

像用于理解环境，惯性数据则连续跟踪指向变化，由此支持面向智能家居的快速选择与控制。多模态融合增强了不同姿态和对象外观下的可用性，却也引入设备佩戴、跨传感器标定和数据同步开销。总体而言，这些系统说明射频也能借助阵列或异构传感器获得方向，但通常要求设备预注册、环境建图或维护空间坐标与网络地址的映射；用户快速切换目标时，空间线索与通信身份之间仍可能出现绑定断点。




图 2.5 无线测位发现方法原理示意

第三类工作越过一次性选择，关注虚拟表示与物理状态的持续一致。**BISHARE**^[51]支持手机与头戴式 AR 之间的双向绑定：头显识别手机并在其周围呈现空间内容，手机又可充当输入表面控制虚拟对象，从而在两个终端之间传递界面和操作。**Sketched Reality**^[52]允许用户在 AR 中绘制运动或结构意图，再将虚拟草图转换为实体机器的动作，使数字设计和物理执行形成往返反馈。**MechARspace**^[53]则为可动玩具建立虚实双向映射：物理玩具的状态能够更新 AR 表示，AR 中的编辑也可反向驱动玩具，实现实时同步。三项工作把研究从“识别一个对象”推进到“让对象持续可控”。

前三类工作分别解决对象发现、空间选择和状态维持，却常要求用户在各阶段重复拍摄、列表选择或身份确认，因而没有形成连续、直观的交互。注意力驱动的直观交互则利用用户自然产生的手部指向、头向与注视作为共同空间线索，使系统围绕同一关注对象完成候选筛选、身份绑定和后续控制。现有研究通常采用“注意定位、显式确认”的分工：如图 2.6 所示，**Gaze+Pinch** 以凝视快速选择、以捏合确认操作^[17,26]；**Schreiter et al.**表明，头向适合粗粒度缩小范围，视线适合精细修正落点^[54]；**Wilson et al.**则进一步利用注视确定响应对象，但仍需结合任务上下文区分自然观察与操作意图^[21]。因此，注意力线索能够把前三类工作串联为更自然的端到端过程，但不能取代必要的确认与意图判断。

综上，现有工作已形成从视觉发现、无线空间选择到虚实状态维持的分层技术路径，手部指向、头向和注视则可作为贯穿这些环节的注意力线索，减少用户在物理对




图 2.6 注视驱动的注意力选择原理示意

象与数字界面之间的重复映射。然而，这些方法主要回答“用户关注哪个对象”，对“用户是否准备与其交互”的判断仍依赖捏合、按键或语音等显式确认；仅凭方向和注视，还难以区分自然观察、信息浏览与操作意图。因此，要进一步实现低负担且不易误触发的直观交互，需要在目标定位与身份绑定之后继续识别用户的交互意图。下一节将据此梳理眼动与脑电信号在意图识别中的相关研究，并分析二者单独使用及多模态融合时的能力边界。

2.3 基于眼动、脑电信号的意图识别

眼动与脑电分别提供空间注意和神经活动的可观测线索，是从“用户看向哪里”进一步推断“用户是否准备交互”的两类主要信号。现有研究大致沿三条路线发展：利用眼动选择目标并通过外部动作确认，利用诱发或自发脑电识别选择与任务状态，以及融合眼动、脑电和动作信号进行多模态意图分类。三条路线逐步增加了对隐式意图的刻画能力，但其研究对象、交互条件和输出结果并不相同。

Jacob 早期使用视线指定界面元素，并提出眼睛同时承担观察与输入功能所导致的“米达斯接触”问题^[12]。此后，眼动交互形成了“视线定位目标、其他模态确认动作”的基本思路。Gaze+Pinch^[17]以凝视完成快速定位、以捏合完成选择和操纵；后续研究进一步从精度、舒适度、反馈和误触发等方面总结了这种眼手分工的设计边界^[26]。这类方法能够避免把每次注视直接解释为命令，但意图最终仍由手势、按键或语音等显式动作表达，眼动主要承担空间指向功能。眼动从界面选择扩展到现实环境后，还需要解决测量与对象映射问题。Feit et al. 表明，眼动准确度和精密度会随用户、屏幕区域及标定状态变化，并限制可可靠区分的目标尺寸与间距^[24]；Liu et al. 对 gaze-to-object 算法的比较进一步说明，二维注视点到三维现实物体的归属并非简单的相交判断^[25]。因此，现有眼动工作已经较好地回答了“以视线选择哪个候选目标”，但多数研究将选择结果交给已知界面或预建模场景处理，并不同时解决现实对象的数字身份识别和后续通信。

脑电图（Electroencephalography, EEG）具有无创和时间分辨率高的特点，相关工




图 2.7 基于视觉刺激脑电的输入系统原理

作可分为诱发式选择和自发式意图识别。诱发式方法通过人为刺激建立神经响应与目标之间的对应关系。如图 2.7 所示，Farwell 与 Donchin 的 P300 拼写器利用用户关注低概率刺激时产生的事件相关电位确定字符^[55]；SSVEP 方法^[56]则依据注视周期刺激所产生的稳态频率响应区分目标^[57]。这类方法的目标集合和神经响应关系明确，适合离散选择，但依赖闪烁刺激、重复试次或时间锁定过程，其所识别的是对预设刺激的选择，而不是自然观察过程中自发形成的操作意图。自发式方法不依赖目标持续闪烁，而是从任务过程中产生的脑电活动推断用户状态。Miao 与 Hou 对浏览、搜索和处置等五类隐式交互意图进行多任务建模，说明 EEG 能够提供不同任务状态之间的区分信息^[58]。相较于诱发式范式，这一路线更接近自然交互中的“是否准备行动”，但现有研究多在受控界面和实验室设备上完成离线分类。可穿戴 EEG 还普遍受到低信噪比、非平稳性、个体差异和运动伪迹影响^[59]，因而仅凭脑电较难同时确定用户所面对的空间目标及其现实身份。

如图 2.8 所示，眼动擅长表征空间注意，而 EEG 可能包含事件驱动的神经活动，两者具有天然互补性。王崴等通过决策级融合组合眼动的空间、行为特征与 EEG，对多类人机交互意图的识别优于单一模态^[60]。Yi et al. 将 P300 与瞳孔、视线响应输入双流多尺度网络，用于意识障碍患者的是/否通信，表明眼动信息可以补充脑电响应；不过，该任务仍由强刺激和二选一答案限定^[61]。这些工作证明了眼动与 EEG 融合的可行性，但主要面向受控界面中的离散输出。近期研究开始把多模态意图识别扩展到人机协作和更丰富的交互类别。Khanna et al. 在人机交接任务中比较 EEG、视线和手部运动，发现视线能够更早、更准确地预测交接意图，而 EEG 并未在所有条件下带来同等增益^[62]。Zhu et al. 进一步通过跨模态注意和动态集成融合 EEG、眼动与手势，实现六类交互意图分类^[63]。前者说明不同模态的贡献取决于具体任务，后者则将融合目标由二元选择扩展到多类意图；但两者的输出仍止于对既定任务标签的识别，没有继续




图 2.8 眼动脑电混合具身协作原理示意

回答意图所指向的现实对象如何被发现、验证并建立交互链路。

现有研究已由眼动目标选择、诱发式脑机选择发展到自发 EEG 与多模态意图分类，为识别关注目标和任务状态提供了基础。然而，这些工作大多以屏幕元素、预设刺激或既定协作任务为对象，尚未把自然注意、现实对象身份和通信会话贯通。Omnisight 在其基础上进一步面向物理多对象环境，以视线驱动光学对象绑定，以眼动与 EEG 区分观察和操作，并把识别结果落实到同一目标的可持续交互。

第三章 本文工作及当前进展

3.1 技术挑战

在人机共生环境中，用户面对的不是一台预先连接的设备，而是分布在物理空间中的多个潜在交互对象。一次自然的定向交互，需要把用户“面向哪里”的空间线索依次转化为唯一的物理目标、可验证的数字身份、明确的操作意图和可持续的信息通道。现有视觉识别、无线发现和凝视输入通常分别解决其中一个环节，环节之间的割裂却会造成目标错选、身份错配、无意触发或会话中断。结合前两章对注意目标解析、物理-数字身份对齐和交互闭环保持的分析，本文需要解决三个逐层递进的系统性难题。

受限移动终端上空间指向、对象身份与空间信息的一体化难题。 用户用手机指向对象时，设备姿态提供了明确但短暂的空间选择线索；摄像头可以看到目标，却难以仅凭外观区分同类实体，无线发现可以获得设备地址，却不能证明该地址对应当前所指对象。如果目标选择、身份读取和空间注册分别依赖拍摄、扫码、设备列表与连接配置，用户就必须在物理对象和数字界面之间反复映射。与此同时，商用手机的闪光灯、滚动快门摄像头和有限算力又受到运动模糊、视角变化、环境光干扰和弱反射信号的共同约束。因此，第一个难题是在不增加专用读写器和预先无线配对的条件下，利用同一方向性光学过程完成目标筛选、身份获取、数据解码与位姿估计，使“指向的实体”与“读取的数字对象”在移动过程中保持一致。这一难题对应 RetroAR，构成注意力驱动定向交互的对象绑定基础。

穿戴式观察条件下目标选择、双向通信与低负担操作的协同难题。 将交互入口由手机迁移到智能眼镜，可以避免反复掏出和举起设备，使交互方向更贴近日常观察方向，但也削弱了“主动持机指向”所包含的明确操作信号。眼镜端还面临发射功率、接收视场、器件尺寸和佩戴姿态等限制；对象端既要准确接收眼镜发出的控制信息，又要把身份和状态沿原方向可靠返回，并避免环境光、邻近标签和非目标用户造成误响应。由此，第二个难题是在无需预注册和额外无线连接的条件下，将佩戴式方向选择、显式操作确认、目标端按需响应以及身份与状态回传组织为同一条低时延双向链路，使用户能够从“举机指向后读取”推进到“面向目标即可就地交互”。这一难题对应 EchoSight，并在 RetroAR 的单向信息获取和空间注册基础上，将系统能力扩展为面向同一对象的双向控制与反馈。

自然注意条件下精确目标对齐、操作意图判别与持续会话的闭环难题。 即使眼镜

光轴能够近似表示观察方向，它仍不等于眼球的真实注视方向；即使视线已经落在某个对象上，也不能说明用户希望立即操作。标定误差、设备滑移、头眼协同和相邻目标会影响视线到对象的映射，自然扫视、信息查看与主动控制又可能表现出相似的注视行为，直接触发容易产生“米达斯接触”式误操作。进一步地，定向光适合核验当前目标，却会因转头、移动和遮挡而中断，不适合独自承担后续持续会话；蓝牙适合维持连接，却不能天然证明其设备身份就是用户刚刚注视的物理实体。因此，第三个难题是联合解决“真正看向谁、是否想操作、如何始终与同一对象交互”：既要实测眼动驱动光束对齐和光学身份验证，又要检验脑电能否在眼动之外提供稳定且值得其佩戴成本的意图证据，还要建立光学目标标识与无线设备身份之间的可验证绑定，并处理授权、切换、超时、重绑定和会话恢复。这一难题对应 **Omnisight**，把前两项工作的对象绑定与就地交互进一步推进为低误触发、可持续的注意力交互闭环。

3.2 研究工作总览

针对上述三个难题，本文按照“外化指向—贴近观察—解析意图”的注意力线索演进，以及“对象绑定—双向交互—持续闭环”的系统能力演进展开研究。首先，**RetroAR** 利用手机闪光灯、逆反射标签和后置摄像头构成同向可见光链路，在商用移动终端上验证空间指向能否统一目标选择、身份读取和空间定位；其次，**EchoSight** 将该方向性绑定机制迁移到智能眼镜，以眼镜端 **SightReader** 和对象端 **EchoTag** 构建双向近红外链路，研究低负担的就地识别、控制与反馈；最后，**Omnisight** 在前述光学对象绑定基础上引入实测眼动、主动可调光束和眼脑多模态判别，并以“光学选择与核验、蓝牙维持会话”的分层机制贯通目标、意图与后续操作。三项工作不是三个孤立系统，而是依次放宽主动手持、设备朝向和全光会话等假设，逐步检验从“所指即所控”到“所见即所控”，再到“所思即所控”的可行性及能力边界。

本文以实现人机共生环境中的注意力驱动定向交互为研究目标，围绕目标选择、身份绑定、意图确认和会话保持等关键环节开展系统研究。三项工作分别以手机指向、眼镜观察方向和实测眼动为交互入口，按照“所指即所控—所见即所控—所思即所控”的路径逐步降低显式操作负担，并扩展系统对用户注意与交互意图的理解能力。具体研究内容与当前进展如下。

3.3 RetroAR：基于手机指向的可见光非接触定向交互系统

3.3.1 引言

移动增强现实使用手机、平板电脑等移动设备连接物理世界与虚拟信息。摄像头捕捉环境中的对象，系统在屏幕中叠加其数字内容，用户还可进一步向对象发送控制命令。在智能家居、公共设施和人机协作等场景中，用户往往不是持续控制一个固定对象，而是在移动过程中与多个对象进行短时、偶发的交互。因此，系统首先需要从视野中的候选对象中确定用户当前所指的目标，再获得该对象的数字身份并建立数据通道。这个过程的时间和操作开销直接影响移动增强现实交互的连续性。

本文设计的 RetroAR 整体交互概念如图 3.1所示：用户用手机指向目标，光束同步完成候选筛选和数据交换，手机界面再依据回传身份呈现增强内容。



图 3.1 RetroAR “所指即所控”的交互场景与系统整体概念

3.3.2 研究背景

现有方案通常将上述过程拆分为视觉识别与无线通信两个环节：摄像头通过外观、纹理或二维码推断对象身份，随后再通过 Wi-Fi 或蓝牙建立连接。该组合能够完成任务，但存在两个相互关联的问题。一方面，无线信号全向传播，设备发现结果无法直接表达用户的位置和指向；当周围存在多个同类设备时，用户还需要在列表中重新选择。另一方面，外观匹配依赖预先采集的特征或云端数据库，二维码扫描则要求用户调整距离和角度并保持画面稳定。即使摄像头已对准目标，视觉标识所表示的身份和最终连接的无线地址也仍由软件映射维系。连接、认证和数据库维护由此成为偶发交互中不可忽略的固定开销。

3.3.3 系统概述

RetroAR 的核心思路是直接利用光的方向性保存手机指向所包含的空间信息。用户将手机朝向目标时，后置闪光灯的光束只覆盖视线范围内的一小片区域；目标上的动态光标签 ViTag 接收入射光，并将身份或状态调制到沿原方向返回的反射光中；手机后置摄像头同时接收数据并观察标签的空间位置。目标选择、身份读取和后续空间注册因而发生在同一条现场光学链路中，不需要云服务，也不需要先从无线设备列表中建立连接。该过程将传统可见光逆反射通信从单纯的数据链路扩展为面向移动增强现实的定向交互媒介，使用户能够通过“指向目标”完成对象筛选，并通过“收到该目标的回波”确认物理实体与数字身份的一致性。

系统由移动读取器和 ViTag 两部分组成，二者均包含发送和接收单元。移动读取器使用商用手机已有的闪光灯发送下行数据，以后置摄像头接收 ViTag 返回的上行数据；ViTag 使用光电二极管接收闪光灯信号，以覆盖在逆反射材料上的液晶像素矩阵调制回波。一次完整交互包括标签唤醒、数据编码与回送、图像采集、标签检测、六自由度位姿估计、数据解码和界面生成。与静态二维码相比，ViTag 能够按需返回动态数据；与单像素发光标签相比，其二维液晶阵列同时提供空间编码和几何锚点；与传统专用可见光读写器相比，手机侧仅使用已有闪光灯与摄像头，从而保持对常见移动增强现实终端的兼容性。

3.3.4 系统设计

将可见光逆反射通信迁移到手持移动增强现实场景，需要同时解决硬件兼容、复杂光学背景和移动跟踪三个挑战。首先，系统不能依赖体积较大的专用光学读写器，而要在商用手机有限的闪光灯功率、相机帧率和计算能力下完成双向通信。其次，室内灯光、镜面反射和眩光会在图像中产生与标签相似的高亮区域；如果标签搜索和解码耗时过长，定向选择所节省的时间会被视觉处理抵消。最后，手持手机会持续平移和旋转，标签的尺度、透视形变和亮度随之变化，系统既要稳定恢复数据，又要实时输出足够准确的六自由度位姿，才能支持增强内容的连续叠加。

面向商用移动终端的收发结构。 读取器可以是配有 LED 和摄像头的智能手机或平板电脑。原型使用手机后置闪光灯的高频开关携带下行比特，同时用后置摄像头捕捉 ViTag。相机镜头前附加偏振片，以削弱具有单一偏振方向的眩光和反射，并提高标签区域的局部对比度。该设计复用移动终端已有传感器，除偏振片外不改变手机内部硬件，主要通过软件控制与图像处理完成通信和跟踪。

ViTag 的接收端由 Hamamatsu S6036 光电二极管、带高通滤波器的跨阻放大电路

和电压比较电路组成，放大器采用 TI OPA344；发送端由液晶像素矩阵和其下方的 3M Scotchlite 8910 逆反射材料组成。液晶像素本身不主动发光，而是通过改变光学状态调制手机闪光灯产生的回波。原型实现了三种形态：与商用液晶屏集成的 $15.5\text{cm} \times 8.7\text{cm}$ 八级标签，以及尺寸分别为 $5.8\text{cm} \times 6.6\text{cm}$ 和 $12.8\text{cm} \times 12.8\text{cm}$ 的四级分体标签。这里“等级”表示液晶方阵单边的像素数量，像素总数保持为完全平方数，以维持规则矩形外形并支持位姿计算。

ViTag 的空间布局兼顾通信与检测。液晶矩阵最外圈留出空白，使下层逆反射材料形成连续明亮边框，便于从复杂背景中提取标签轮廓；液晶表面的前偏振片被移至摄像头镜头处，使像素状态变化不易被肉眼察觉，同时抑制正交偏振方向的背景噪声。液晶像素数可以按应用定制，多像素阵列既承载数据，也提供稳定的角点与网格结构。由此，同一标签同时承担光通信节点和增强现实空间锚点两种角色。

读取器、ViTag 及三种标签形态的对应关系将在图 3.2 中展示，用于说明第一个设计如何在商用移动终端约束下组织完整收发链路。




图 3.2 RetroAR 移动读取器、ViTag 硬件组成及三种标签形态

下行唤醒与时空混合编码。 交互开始时，手机通过闪光灯发送下行帧。帧中包含用于同步的前导码、区分读写请求的类型字段以及用于目标过滤的身份字段。ViTag 的接收电路使用高通滤波器避免环境光直流分量造成饱和，下行链路相应采用差分编码。标签检测到前导码并完成请求解析后，才准备上行响应，从而把回传限制在用户主动照射的时间窗口内。

上行链路需要对抗相机动态范围、环境光和局部反射共同造成的亮度波动。系统利用液晶矩阵同时具有空间维和时间维这一特点，提出时空混合编码。以四级标签为

例，八个字节可以并行传输；每个字节的八位原始数据先在时间轴上经曼彻斯特编码扩展为十六位序列，再依次放置到连续空间帧中的固定像素对。每个数据像素与相邻像素取相反状态，相当于在空间维再次引入曼彻斯特式冗余。时间维的电平跳变避免连续直流状态带来的漂移，空间维的互补像素则为每一帧提供局部参照，使系统无需依赖一个适用于所有光照条件的固定亮度值。

解码过程与上述编码结构相对应。系统先统计单帧中各液晶区域的亮度直方图，并以 K-means 聚类得到该帧的自适应二值化阈值；随后用高斯算子计算每个像素中心邻域的平均亮度，获得空间解码结果。跨帧阶段再按像素位置串联亮度序列，完成时间维曼彻斯特解码。对于同一比特，空间维和时间维会给出两组结果，系统根据像素亮度到各自分割阈值的归一化距离计算置信度，并据此融合。该方法将固定阈值判决转化为随帧变化的相对判决，以适应手机闪光灯功率、拍摄距离和环境照明的变化。

图 3.3 将对应第二个设计，集中呈现下行帧、时空混合编码和自适应解码之间的关系。




图 3.3 RetroAR 下行帧结构、时空混合编码与自适应阈值解码

移动条件下的快速检测与位姿估计。 若每一帧都在完整画面中搜索标签，移动终端难以维持流畅帧率。RetroAR 因此设计消息级动态兴趣区。系统把成功定位标签的图像记为有效帧，把受噪声影响而未检测到标签的图像记为存续帧。获得有效帧后，下一帧只在最近标签轮廓附近的外扩矩形中搜索；外扩范围根据连续有效帧间的移动幅度动态调整。若当前帧检测失败，系统保留上一兴趣区继续搜索；一条消息传输结束后再重置兴趣区。该策略利用手持运动在相邻帧之间的连续性，减少无关背景参与计算的面积，同时避免偶发检测失败立即丢失目标。

在兴趣区内，系统首先用 Canny 算子提取边缘，利用 ViTag 的逆反射亮边框获得候选封闭轮廓；随后依次排除远离上一位置、形状不近似矩形、位于其他候选轮廓内部或边线弯曲过大的区域。经过筛选后，快速凸包算法给出标签的四个顶点，顶点映射规则确定其与标签物理角点的对应关系，再通过透视变换将拍摄区域恢复为规则网格供后续解码。该流水线把“在背景中找到标签”和“在标签内部恢复数据”分开处理，在降低搜索成本的同时保留角点精度。

四个角点也用于三维空间注册。系统将已知标签平面上的三维控制点与图像中的二维投影点建立对应关系，把位姿求解转化为 Perspective- n -Point 问题。ViTag 的空间编码能够呈现类似棋盘的规则结构，初始阶段可直接用于亚像素角点提取和相机内参标定；运行阶段采用 EPnP 算法估计旋转矩阵和平移向量，得到相机相对标签的三轴位移以及滚转、偏航和俯仰角。对坐标关系求逆后，系统即可获得标签在相机坐标系中的位姿，并按正确透视关系叠加虚拟菜单或三维内容。通信所使用的同一块液晶矩阵由此也完成六自由度跟踪，不再需要额外视觉标签。

图 3.4 对应第三个设计，展示从动态兴趣区到凸包角点、数据恢复和六自由度位姿输出的完整处理流水线。

3.3.5 系统验证

系统实验使用华为 Mate 30 Pro 作为读取器，后置相机设置为 720p、60fps，手机和 ViTag 分别固定在相对放置的三脚架上。实验使用两种不同尺寸的四级分体 ViTag，以考察标签尺寸的影响。对距离、视角、照明条件和闪光灯频率等变量，每种设置均发送十次预定义信息并计算平均误码率；此外连续传输 32 字节信息测量上下行最大数据率，以十秒内的平均值作为结果。位姿实验使用同尺寸 ArUco 标签和 OpenCV ArUco 库给出的平移与旋转结果作为参照。结果如图 3.5 所示。

通信距离随摄像头分辨率提高近似线性增长，因为更高分辨率能在远距离保留更多液晶像素细节。大尺寸 ViTag 在 2K 分辨率下最远可达到约 7m，但图像处理时间和移动端算力开销也随之上升；在多数商用设备支持的 1080p 设置下，系统工作距离约




图 3.4 RetroAR 标签检测、动态兴趣区、凸包角点提取、解码与六自由度位姿估计流水线

为 4m，能够覆盖典型房间尺度。综合不同光照与视角条件，RetroAR 最远可在约 4m 距离和约 100° 视角范围内保持可靠交互。

六自由度估计结果表明， x 、 y 方向平移误差中位数分别为 1.0cm 和 1.3cm， z 方向为 2.5cm。实验分析表明，深度方向误差较高，这是因为标签沿该方向移动时更易受到眩光和垂直光源反射影响，进而降低角点定位精度。滚转、偏航和俯仰角误差中位数分别为 4.7°、5.1° 和 7.5°；俯仰角下标签倾斜引入更多环境反射，因此误差相对较大。这些结果说明系统能够在移动增强现实所需的房间尺度内同时完成数据读取和厘米级空间注册，但不同轴向对光学噪声的敏感度并不相同。

标签功耗体现出尺寸与通信距离之间的权衡。两种刚性 ViTag 在传输状态下的最大功耗分别为 2.82mW 和 12.17mW，较大的液晶面积和更多像素需要更高驱动功耗，同时也能在远距离形成更清晰的图像。小尺寸标签使用标准 1740mAh 锂电池可工作三个月以上。原型的实际数据率约为 400bps，能够承载设备身份、状态和非接触控制命令，但并不面向高带宽内容传输；其性能边界主要来自手机闪光灯控制、相机帧率和液晶响应速度。




图 3.5 RetroAR 系统实验：分辨率与距离、六自由度位姿误差及标签功耗

3.3.6 用户实验

用户研究比较 RetroAR 与基于 Wi-Fi 扫码、基于 BLE 语音的交互方式，关注总交互时间和主观体验。实验招募 12 名参与者，其中女性 6 名，年龄范围为 20 至 47 岁，中位数为 24 岁。实验环境布置智能灯、智能音箱、自动售货机界面和电梯面板等对象，测试点之间相距 2m。各对象除 ViTag 外还配置 ESP32 以提供免密码 Wi-Fi，并放置包含 UUID 的二维码；BLE 设备则预先与读取器连接并设置唯一名称。参与者可以从华为 Mate 30 Pro、Google Nexus 6P 和 Lenovo Tab P11 中选择读取器，实验相机帧率为 60fps，闪光灯频率为 90Hz。结果在图 3.6 中说明。

实验包含两个场景。智能家居场景要求参与者按照随机生成的三个动作序列控制智能灯和智能音箱，例如开关灯或调节音量；非接触电器场景要求参与者从自动售货机的十个候选物品中购买指定物品，并在电梯面板上选择指定楼层。任务目标由随

机数给出，以排除参与者自主选择内容所带来的时间差异。每个场景重复六轮，三种方法的顺序进行平衡。Wi-Fi 条件下，参与者扫描二维码、连接网络，再在应用中选择目标并发送命令；BLE 条件下，参与者按住语音键说出包含目标与动作的指令；RetroAR 条件下，参与者把手机指向 ViTag 并点击应用按钮。实验将从按下开始按钮到全部动作成功完成定义为交互时间，并在任务后通过七点量表的 NASA-TLX 问卷比较 Wi-Fi 与 RetroAR 的工作负荷，同时收集开放式访谈反馈。

场景完成时间采用 Welch's t 检验分析。智能家居场景中，RetroAR 与 Wi-Fi、BLE 的差异对应 p 值均为 0.002；非接触控制场景中，对应 p 值分别为 0.004 和 0.003。两类场景均显示 RetroAR 的单场景完成时间显著更短，且在需要连续切换多个对象或动作时优势更加明显。进一步排除 Android 系统和底层通信逻辑引入的系统时延后，Wi-Fi 方法在每个任务中用于目标选择和连接的交互开销超过 RetroAR 的两倍；BLE 语音也表现出较大的时间开销和方差。该结果验证了将对象选择和数据返回约束在同一光学方向内，可以减少扫码、列表选择和网络连接造成的固定步骤。

实验同时揭示了原型的具体不足。RetroAR 的交互时间方差大于 Wi-Fi 条件，原因是集成式 ViTag 的接收区域不如二维码醒目，部分参与者需要反复调整手机，使闪光灯光束与标签光电接收器对齐。这说明方向性既带来候选筛选能力，也提出可发现性和对准反馈要求。NASA-TLX 结果中，RetroAR 相比 Wi-Fi 的身体负荷更低，Wilcoxon 符号秩检验得到 $p = 0.03$ ；挫败感也显著更低， $p = 0.04$ 。心理需求和努力程度则未出现显著差异。访谈表明，一部分参与者认可省去公共 Wi-Fi 认证和扫码等待的价值，另一部分参与者已习惯扫码和设备列表，因而并不认为传统流程具有很高的心理负担。定向光学交互在效率与身体负担上的收益得到验证，但界面提示、标签可见性和用户习惯仍会影响实际接受度。

3.3.7 小结

适用范围与能力边界。 RetroAR 的直接适用对象是交换数据量较小、目标切换频繁并且需要空间注册的房间尺度移动增强现实任务。智能灯和音箱实验说明，用户可以在多个对象之间切换并发送开关或参数调节命令；自动售货机和电梯面板实验说明，ViTag 可与公共设施已有液晶屏集成，在不建立无线连接的情况下完成临时控制。标签返回的身份还可以决定手机端显示何种虚拟菜单，六自由度位姿则决定菜单与物理表面的叠加位置。这些能力来自同一次光学读取，因此其价值并非单独提高某一条通信链路的数据率，而是减少“找到对象—确认身份—建立通道—注册位置”之间的重复映射。

系统当前的主要限制是通信范围、吞吐量与移动处理能力。约 4m 的有效距离适




图 3.6 RetroAR 用户实验：两类场景完成时间、纯交互开销及 NASA-TLX 结果

用于房间尺度，无法直接覆盖建筑尺度或远距离目标；提高相机分辨率虽然可把大标签的上行距离扩展到约 7m，却会增加逐帧检测与透视恢复的计算成本。针对这些限制，本文归纳出两个相互配合的改进方向：一是重新设计读写器的光学发射与接收单元，绕过手机闪光灯及 Android 软件控制的限制，使下行距离超过 5m；二是进一步优化跟踪算法，使其能在 4K 图像上实时运行，以同步扩大摄像头上行的可读范围。这些改进方向尚未由当前原型验证。

约 400bps 的实测数据率足以传输设备身份、状态和控制命令，但不足以承担大文件或实时媒体。进一步分析表明，部分高端手机支持最高 720fps 的高速摄像，若复用此能力，上行数据率有望提高到数千比特每秒；若为手机闪光灯增加专用硬件控制并绕过软件时钟限制，下行还可能获得更高速度。相应设想包括定向文件共享以及第一人称增强现实对抗游戏中的即时多目标交互。上述速率提升和应用属于后续展望，RetroAR 已完成的验证仍限定在现有手机、液晶标签和低速控制数据范围内。

此外，系统依赖视距和可见光照射，遮挡会直接中断链路；更大的 ViTag 能改善远距离成像，却增加标签面积与驱动功耗；更窄、更明确的方向约束有助于选择目标，却要求用户更准确地把闪光灯照到接收区域。这些取舍解释了为何用户研究中 RetroAR 平均耗时较低而方差仍可能较大。因而，实际部署除优化物理链路外，还需通过标签外观、界面准星或即时反馈帮助用户理解有效照射区域。该认识也为后续 EchoSight 的双元件对齐检测和显式反馈设计提供了直接依据。

RetroAR 在商用移动终端上把手机指向、对象身份读取、动态数据通信和六自由度空间注册统一到一条可见光逆反射链路中。ViTag 通过液晶矩阵与逆反射材料返回数据，时空混合编码和自适应解码提高复杂光照下的可靠性，消息级动态兴趣区与快速凸包检测则使移动跟踪能够在有限算力下运行。系统实验给出了约 4m、100° 的房间尺度工作范围以及厘米级位姿精度；12 人用户研究进一步表明，“所指即所控”能够显著减少多对象交互中的选择和连接开销。该工作也明确了其边界：当前距离和约 400bps 数据率适合身份、状态和控制命令，标签对准提示与远距离、高分辨率实时处理仍需改进。相关成果发表于《电子学报》。

3.4 EchoSight：面向智能眼镜的双向近红外直观交互系统



图 3.7 EchoSight “所见即所控”的双向虚实交互场景

3.4.1 引言

增强现实早期主要增强用户对环境的感知：系统采集位置、姿态和物理锚点等信息，再把数字内容叠加到真实世界中。随着空间计算设备逐渐具备手势识别、环境感知和联网控制能力，增强现实还需要支持用户主动改变物理对象的状态。例如，用户在眼镜中查看灯具当前亮度后，应当能够直接调节亮度；查看机器人状态后，也应当

能够向同一机器人发送控制命令。这类双向虚实交互要求物理状态与虚拟界面持续对应，并使从被动感知到主动控制的转换足够流畅。

本文设计的 EchoSight 整体使用场景如图 3.7所示，SightReader 与 EchoTag 围绕用户当前面向的对象建立临时双向光学绑定，从而把识别、连接与控制组织为连续过程。

3.4.2 研究背景

现有双向系统在主动控制环节仍存在两个主要瓶颈。第一个是准确识别。二维码或视觉特征通常需要先拍摄对象，再把图像中的标识与本地或云端数据库匹配；目标较小、距离较远、光照不佳或相邻对象外观相似时，用户还需移动到合适位置并保持画面稳定。第二个是低时延通信。完成视觉识别后，系统通常还要借助 BLE 或 Wi-Fi 查找、配对或切换连接。对于长期固定在同一网络中的设备，这些成本可以通过预注册和常连接摊薄；对于公共空间、多用户、多目标以及临时相遇的对象，每次选择新目标仍会重复出现。识别和连接作为两个独立阶段，也容易使一次本应连续的空间行为被切分为若干界面操作。

3.4.3 系统概述

EchoSight 将 RetroAR 所验证的方向性对象绑定迁移到智能眼镜，并进一步形成完整的双向控制链路。用户看向目标并做出指向与轻触手势后，眼镜端 SightReader 发射调制近红外光；目标端 EchoTag 接收请求，判断自身是否与用户方向对齐，再通过调制反射光返回身份和控制菜单。SightReader 解析返回信息，在眼镜界面显示该对象支持的动作；用户继续通过手势发送命令，完成后移开视线，界面随之关闭。目标身份、界面内容、控制命令与状态反馈均在局部光学链路中按需交换，无需预先注册到外部数据库，也无需建立额外无线连接。

这一流程称为“所见即所控”。其中，“见”由眼镜朝向和界面中心瞄准区域近似表示，而非精确眼动测量；指向与轻触手势作为显式确认，防止仅因自然观察而立即触发操作。光束的空间覆盖先筛选候选对象，双通道对齐判断再确认 EchoTag 位于视轴附近，回传身份则完成物理目标与数字对象的现场核验。通信结束后 EchoTag 立即休眠，使数据交换具有类似回声的按需响应特征。相较于手机方案，用户无需反复取出、举起和调整手持终端；相较于纯视觉和无线方案，对象选择与数据通道由同一方向关系约束。

3.4.4 系统设计

EchoSight 需要在轻量穿戴设备上同时实现准确对象识别与低时延双向通信。准确识别的难点在于，单束光覆盖目标并不必然排除邻近 EchoTag，佩戴姿态和器件装配误差也会造成收发光轴偏移。低时延通信的难点在于，系统既要省去关联和配对，又要保证只有当前目标响应，并在环境红外噪声、不同距离和有限发射功率下可靠传输。除此之外，眼镜端的尺寸、重量、功耗和温升直接影响佩戴体验，对象端则需要低功耗待机并支持长期部署。EchoSight 通过双元件光学前端、双波段差分信号和按需回声链路协同解决这些问题。

双元件近红外收发结构。 系统包含 SightReader 和 EchoTag 两个收发器。传统逆反射链路通常在主动端配置一组 LED 发射器和光电二极管接收器，在被动端配置光电二极管与空间光调制器；EchoSight 在两端各设置两组收发单元，构成两条相互独立又可联合判决的近红外通道。两组通道分别工作在 850nm 和 940nm 波段，并配合窄带滤光片抑制其他波长的环境光。SightReader 的每个 LED 与同侧光电二极管组成一组收发对，器件间距和光学中心经过对齐；LED 前使用视场角为 5° 的透镜收束光束。两条通道接收强度的相对关系因此可以反映 EchoTag 是否位于预期光轴附近。

原型以 XREAL X 眼镜和 Samsung Galaxy S21 手机作为运行平台。SightReader 使用两个功率为 1W 的 CREE 红外 LED，以及两个 LightSensing LSSPD-2.5 光电二极管；其处理器为 STM32H750VB，板面积为 7.1cm × 12.2cm。接收链路采用带自动增益控制的跨阻放大器，使系统适应不同距离对应的光强变化；发射链路以快速充放电 MOSFET 驱动 LED 开关。EchoTag 使用相同类型的双光电二极管和两块自制液晶空间光调制器，单块调制区域为 3cm × 3cm，处理器采用低功耗 STM32L432KB，整板尺寸为 6cm × 6cm。移位寄存器与定时器缓存调制数据，再经比较器驱动液晶调制器。

SightReader 最终采用安装在眼镜上方的支架形态，将主要重量分散到眼镜鼻托区域。LED 支撑件使用 H-59 黄铜数控加工，在固定发射方向的同时导出热量；接收舱外壳以 PLA 材料 3D 打印。四层电路板的大面积铺铜进一步帮助散热。该实现仍是研究原型，但其器件选择和结构设计围绕两个明确约束展开：眼镜端要提供足够的发射与计算能力，对象端则以低功耗器件和液晶反射调制避免主动红外发射。

图 3.8 对应穿戴式硬件设计，展示双波段收发前端、SightReader、EchoTag 及其在眼镜上的装配关系。

一步识别与对齐检测。 用户发起交互时，两路 LED 同时向视野中心发送请求。若 SightReader 与 EchoTag 正确对齐，EchoTag 上两个光电二极管接收到的平均直流强度




图 3.8 EchoSight 双元件收发结构、SightReader/EchoTag 原型与眼镜端装配

均超过预设下限，且二者大致相等；如果目标偏离中心，一路信号通常明显强于另一路，或至少一路不足以触发。系统允许一个小的差异阈值，以容纳器件制造、装配和实际佩戴造成的不一致。只有同时满足强度与平衡条件的 EchoTag 才进入后续解码和应答，视野边缘或光束覆盖不完整的标签保持静默。

为抵消突发环境光，两波段下行信号采用相反幅度的差分形式：850nm 通道处于高电平时，940nm 通道处于低电平，反之亦然。环境光变化通常会同向影响两路接收值，对两路信号相减可以保留互补调制分量并削弱共模干扰。EchoTag 只有在两路直流强度近似相等、瞬时电平相反且解码数据一致时，才把自己判定为预期接收者。确认后，它把身份返回 SightReader；该身份同时作为后续数据包的认证键，用于排除非目标标签。于是，传统“拍摄标识—查询数据库”的两步识别被压缩为直接从当前光学目标读取身份的一步过程。

该设计仍保留用户侧的明确触发。用户把界面中心的圆形准星对准对象，再做出指向和轻触动作，系统才发送识别请求。识别完成并取得设备身份与菜单内容时，眼镜播放菜单打开提示音；用户转向其他对象后，系统识别方向变化，关闭原菜单并播放对应提示。光学方向承担候选筛选和现场核验，手势承担操作确认，声音与界面承担过程反馈，三者共同避免把普通观察直接解释为控制意图。

图 3.9 对应一步识别设计，重点说明对齐和偏离状态下两路直流强度、互补调制和目标标签唤醒条件的差异。

无连接双向通信。 完成对齐和身份确认后，EchoTag 通过双液晶空间光调制器改变入射载波的反射状态，将数据沿近原路返回 SightReader。近红外下行光束本身高度定向，逆反射上行也把能量集中送回光源附近，因此一对 SightReader 与 EchoTag 可形成局部双向通道。后续分组携带已确认的目标身份，未对齐或身份不匹配的标签不响应。链路不执行 BLE/Wi-Fi 式关联过程，数据仅在需要交互时传输，结束后 EchoTag 恢复休眠。

光学信道需要足够高的信噪比才能区分弱反射与背景变化。EchoSight 使用脉宽编码，把数据表示为不同宽度的短脉冲；有数据时发送强而短的脉冲，其余时间保持空闲。该方式一方面提高瞬时信号与背景之间的对比度，另一方面降低 LED 的平均开启时间。下行主要承载菜单和控制命令，上行主要返回身份、状态与确认，因此系统允许非对称速率。对以短消息为主的对象控制，这一分配与实际数据方向一致。

界面与交互闭环。 EchoSight 的应用以 Unity 2022.3.8f1 和 XREAL NRSDK 2.2.0 实现，后端运行在与眼镜连接的 Android 手机上。EchoTag 将图像、按钮和标签等界面元素序列化为符合 XML 的字符串，通过光学链路按需传输；SightReader 解序列化后




图 3.9 EchoSight 双通道对齐检测、差分信号与一步身份获取机制

填充到预定义的增强现实界面容器中。界面数据直接来自当前目标，不需要在眼镜端维护“设备身份—界面模板”的预置数据库。用户识别目标后，视野左侧显示该设备支持的手势和功能，并可通过捏合、移动等手势改变灯光亮度、色温或扬声器状态。目标切换时，身份、菜单和数据来源随光学链路一同切换，使界面内容与当前物理对象保持一致。

完整的“看向—确认—读取菜单—发送命令—移开关闭”闭环将在图 3.10中展示，对应无连接通信与界面反馈设计。

3.4.5 系统验证

系统实验使用 XREAL X、Samsung Galaxy S21、SightReader 和 EchoTag 原型，考察通信距离、视角、数据率、功耗、温升以及多标签可分辨性。距离和视角实验分别在约 1000lux 的直射日光、400lux 的办公室照明和 100lux 的暗环境下进行，以总体数据误码率衡量可靠性。数据率测试在 3m、典型办公室光照下连续发送 32 字节预定义消息，记录瞬时速率和错误比特。各项实验重复三次并报告平均结果。功耗由 Monsoon HV Power Monitor 测量，温升由 FLIR Lepton 3.5 热成像相机记录；SightReader 每十秒发送一次随机数据，以模拟常见的间歇式交互。结果汇总在图 3.11中。




图 3.10 EchoSight 双向交互 workflow、无连接数据交换与增强现实菜单反馈

以误码率 10^{-3} 作为可靠通信阈值时，下行最远工作距离约为 5.5m，逆反射上行约为 5.0m。视角实验显示，当用户位置与 EchoTag 法线夹角处于 -60° 到 60° 之间时，系统可维持阈值以内的误码率，即总视角范围约为 120° 。这些结果覆盖常见房间尺度交互。原型下行原始数据率最高约为 110kbps，上行最高约为 512bps；上行瓶颈来自液晶空间光调制器仅有数百赫兹的刷新能力。由于菜单和命令主要通过高速下行传输，上行只承载短响应，实验所覆盖的应用仍可正常运行。

功耗结果与脉冲发送过程一致。SightReader 发射时峰值电流约为 150mA，平均电流维持在约 20mA；EchoTag 平均电流低于 10mA，在 3V 供电下为数十毫瓦量级。由于标签只在请求到达时工作，实际长期部署中的平均功耗还可通过 MCU 深度睡眠和周期唤醒进一步降低。SightReader 的 LED 区域温升实测约为 7°C ，低于设计控制在 10°C 内的目标，说明脉宽编码、黄铜支架和电路板散热能够限制间歇交互中的热积累。

多标签实验进一步验证方向选择能力。实验把两个 EchoTag 放在以 SightReader 为圆心的等距圆弧上，逐步缩小标签间角距；每个位置进行 1000 次 32 字节随机字符串往返，以正确返回相同字符串作为成功识别。在不超过 3m 的典型距离和 5° 透镜下，达到 95% 识别率所需的标签边缘间距约为 10cm。在 2 至 3m 距离内， 5° 透镜支持在 1m 圆弧范围内部署最多 7 个标签；使用 1° 窄视场透镜时，5m 距离可支持最多 16 个标签，此上限同时受到 6cm 标签物理尺寸约束。视场越窄，多目标分辨率越高，但用户对准要求也相应提高。

佩戴过程中头部可能发生倾斜，因此实验还将 SightReader 固定在舵机上，从 0° 到 90° 每隔 15° 测试一次。在 3m 的单标签条件下，倾斜不超过 60° 时识别率保持在 90% 以上， 75° 时下降到约 70%。综合不同距离和光照，倾斜不超过 30° 时各距离平均识别率均高于 90%；在 5m、 90° 极端倾斜下约为 53%，短距离下仍高于 80%。结果表明双通道设计能够容纳日常佩戴中的中等倾斜，但远距离和极端姿态仍需更强的纠错或重传机制。

3.4.6 用户实验

用户研究旨在检验一步识别和无连接通信能否改善日常增强现实交互。实验搭建包含智能灯、RGB 氛围灯和智能音箱的模拟物联网环境，每台设备均配置 BLE 模块、用于扫码识别的二维码以及 EchoTag。为控制视觉尺寸因素，二维码与 EchoTag 均为 $6\text{cm} \times 6\text{cm}$ 。参与者坐在距离三个对象约 2m 的沙发上，如有需要可以起身靠近。研究招募 12 名参与者，其中男性 7 名、女性 5 名，平均年龄 24.2 岁；3 人具有丰富 AR/VR 经验，4 人有少量经验，5 人很少或从未使用过相关系统。图 3.12 并列给出实验场景、




图 3.11 EchoSight 系统实验：距离、视角、数据率、功耗、多标签间距与头部倾斜

交互阶段划分、分阶段耗时与主观量表结果。

实验比较二维码扫描、语音控制和 EchoSight 三种方法，并将一次交互分解为注册、识别、连接和动作四个阶段。二维码方法需要预先把扫码得到的身份映射到物理设备，交互时对准并保持稳定完成扫描，再建立 BLE 或 Wi-Fi 连接并操作界面；语音方法需要预先映射设备名称，交互时说出设备名、建立无线连接，再说完整命令；EchoSight 无需注册，用户看向设备后直接取得身份，数据在点对点光学链路中交换，再依据界面提示使用手势操作。注册是一次性部署成本，不计入计时，实验主要记录识别、连接和动作三个阶段。

参与者首先接受系统介绍和十分钟原型演示，学习开启 AR 模式、使用视线方向与手势操作全息界面，并练习调节亮度和色温。正式计时任务从六种预定义动作中随机抽取三个，包括智能灯亮度增减、RGB 灯色调冷暖变化和扬声器开关；动作顺序经过随机与平衡处理，可能要求参与者在三个目标之间切换。每名参与者分别使用三种方法完成任务。随后设置自由体验环节，允许参与者在没有指定目标的情况下使用各方法。实验结束后，参与者填写七点量表问卷，评价心理负荷、身体负荷、流畅性和挫败感，并接受简短访谈。

分阶段计时显示，EchoSight 在识别阶段相较二维码和语音方法实现约 5 倍的时间缩短。二维码扫描的时间和方差明显受用户稳定持姿、是否靠近目标等行为影响；语音识别的平均时间和方差小于二维码扫描，两样本 t 检验和 F 检验均得到 $p < 0.001$ ，其耗时主要随设备名称长度和说话速度变化。EchoSight 直接通过光链路读取当前对象身份，省去画面稳定扫描和完整说出名称的过程，因而同时降低了平均识别时间和不可控波动。

在连接阶段，二维码和语音方法均使用 BLE 5.0，需要数秒建立数据链路，两者均值与方差没有显著差异，检验结果分别为 $p_t = 0.75$ 和 $p_F = 0.2$ 。EchoSight 不执行

无线关联，只需完成短时认证和点对点光路建立，因此该阶段显著缩短。同时需要指出，在固定智能家居或办公室内，预注册并保持常连接可把传统方法的连接时延降至毫秒量级；EchoSight 的优势主要体现在无法预先注册、需要跨区域频繁切换设备的机会式交互中。动作阶段由具体输入方式决定：二维码与 EchoSight 都通过全息界面和手势操作，两者均值无显著差异， $p = 0.31$ ；语音方法因需说出完整命令并等待识别而耗时更长。因此，EchoSight 的主要贡献集中在动作之前的目标识别和通道建立，而不是加速所有手势执行过程。

主观问卷中，EchoSight 与语音控制在心理负荷、身体负荷、流畅性和挫败感四项上总体优于二维码扫描，参与者尤其认可 EchoSight 的整体流畅感。访谈表明，二维码本身并非主要问题，移动到合适位置、保持静止、等待扫描，以及切换目标时重复这些步骤共同造成了割裂感。参与者认为直接看向并控制、或直接用语音控制，更接近日常沟通习惯；同时也指出语音不适合公共服务等隐私敏感场景，而 EchoSight 能够保持静默，并把交互限制在用户与目标之间的定向链路内。定量计时与定性反馈共同支持一步识别和无连接通信对多目标双向交互的改善。

3.4.7 小结

原型应用与能力边界。 本文进一步实现了三类原型应用，以验证 EchoSight 的双向能力。第一类是多目标人机协作。用户可以看向机器人小车或无人机，以手势打开协作菜单并读取目标状态，再沿同一光学链路发送控制命令；切换机器人时不需要在设备列表中断开和重连，只需改变面向方向并重新确认目标。第二类是智能办公室与智能家居。用户可在座位上面向打印机选择文档并发起打印，或调整灯具、风扇、空调和电视等设备；交互菜单从当前 EchoTag 获取，使同一副眼镜可以面对不同类型对象生成相应控制界面。第三类是增强现实社交。用户面向交互对象后可静默获取对方主动公开的电子名片等信息，并以手势保存。三类演示分别对应工业协作、日常物联网和临时社交，但都使用相同的“方向选择—身份返回—菜单呈现—命令发送”流程。

这些演示不改变系统实验所界定的能力范围。EchoSight 的方向性提高了普通窃听器进入光路的难度，光电二极管也不像摄像头那样记录具有空间分辨率的场景图像，但当前原型并未因此自动获得完整安全性。本文将身份验证、密钥交换、链路加密、对象端唯一标识和访问控制列为后续需要结合的机制，包括在读取器侧采用生物特征认证、在标签侧使用数字签名或物理不可克隆函数，以及对应用数据使用成熟的非对称和对称加密。因而，现有结果证明的是现场定向绑定与通信性能，不能替代面向实际部署的安全协议评估。

与未来网络的关系同样需要限定。即使后续 Wi-Fi、蜂窝或其他射频技术继续降




图 3.12 EchoSight 用户实验：实验场景、交互阶段、阶段耗时和主观问卷

低传输时延，机会式双向交互仍需先回答“连接哪个物理对象”。EchoSight 的光学链路可以用于这一识别、核验和初始握手阶段，高吞吐后续业务则可转交其他通信方式。本工作尚未实现这种混合链路，而是把它作为未来网络中的一种分工设想。当前系统在全局交互期间使用近红外链路，其优势是无需外部网络并保持目标方向约束，其代价则是视距依赖和上下行速率不对称。

系统还以头部朝向近似用户关注方向。该方式适用于目标间距较大的常见房间场景，但在小目标密集排列或需要精确指向时，头向不能等同于实际注视。针对这一限制，后续可结合眼动追踪和 MEMS 反射镜，根据头部姿态确定大致范围，再以眼动控制二维光束偏转；这一方案需要双振镜、可调孔径以及可在移动端运行的轻量追踪算法，尚未包含在当前原型中。另一方面，512bps 的液晶上行限制了高带宽双向业务，本文进一步考虑以激光和更高速反射器提高精度与速率。对准方式、高速上行和硬件小型化由此构成 EchoSight 向更细粒度注意交互演进时的主要边界。

EchoSight 以智能眼镜为入口，通过 SightReader 与 EchoTag 构成按需双向近红外链路。双元件、双波段收发结构以两路强度和平衡关系判断对齐，互补差分信号抑制环境光，脉宽编码和身份键支持低功耗、无连接的数据交换。系统实验表明，下行和上行距离分别约为 5.5m 和 5.0m，总可用视角约为 120°，并能在典型房间尺度区分相距约 10cm 的标签。12 人用户研究说明，其识别阶段相较二维码与语音方案约快 5 倍，并减少无线连接切换带来的固定开销。

该工作由此把 RetroAR 的“持机指向并读取”推进为“面向目标并双向控制”，验证了定向光学链路可以同时服务于对象识别、命令发送和状态反馈。其能力边界也较明确：当前系统以头向和界面准星近似注意方向，精细目标选择仍依赖用户对准；110kbps 下行与 512bps 上行适合非对称控制消息，不适合双向高带宽业务；研究原型的眼镜端尺寸也有进一步集成空间。这些限制直接构成后续引入实测眼动、主动光束控制和混合链路的研究动机。相关成果发表于 ACM CHI 2025。

3.5 Omnisight：眼脑联合的注意力驱动意图交互系统

3.5.1 引言

RetroAR 和 EchoSight 已分别验证手机指向与眼镜朝向可以为现实对象提供方向性绑定，但二者仍以设备光轴近似用户的注意方向，并依赖显式动作表达操作意图。Omnisight 进一步面向目标对齐误差、注视与操作意图二义性以及全光链路易中断问题，将实测眼动、事件驱动脑电和混合通信链路组织为完整交互闭环。该研究的重点不是预设脑电能够直接读取意图，而是检验其能否在眼动之外提供稳定且值得佩戴成

本的增量信息。

3.5.2 研究背景

现有眼动交互通常利用视线定位目标，再通过手势、按键或语音确认操作，以避免把自然观察直接解释为命令所导致的“米达斯接触”问题^[12,17]。当目标由二维界面扩展到现实环境时，用户差异、标定状态和设备滑移还会影响注视精度，二维注视点到三维对象的归属也并非简单的相交判断^[24,25]。因此，眼动能够提供比头向更细粒度的空间注意线索，却仍需解决目标映射和操作确认。

脑电研究则表明，事件相关神经活动可用于离散选择或任务状态分类，但可穿戴脑电受到低信噪比、非平稳性、个体差异和运动伪迹影响^[59]。已有眼脑融合研究验证了两种信号的互补潜力，同时也显示脑电并非在所有具身任务中都能带来稳定增益^[60,62]。这些研究主要输出界面选择或预设任务标签，没有继续解决意图所对应的现实对象如何被验证并建立持续通信。Omnisight 因而需要同时检验眼动的空间定位能力、脑电的增量意图信息，以及识别结果到现实对象会话之间的闭环。

3.5.3 系统概述

用户的视线首先驱动定向光完成物理目标选择与身份核验，眼动和脑电共同判断是否存在操作意图，随后由无线链路维持同一对象的持续会话。系统以光学链路回答“当前关注的是哪个现实对象”，以眼脑融合回答“用户是否准备操作”，再把经过核验的光学目标标识绑定到无线设备身份，使目标切换、授权和会话恢复仍受最初的方向性选择约束。

3.5.4 系统设计

Omnisight 的设计沿三个相互依赖的环节展开。第一，眼镜朝向只能提供粗粒度观察方向，系统需要把真实注视点转换为可执行的光束方向；第二，即使用户已经注视对象，也不能直接推断其希望操作，系统需要区分自然观察、状态查看和主动控制；第三，定向光适合完成现场目标核验，却会随转头、运动和遮挡中断，因此还需要在不丢失物理对象身份的前提下转入可持续会话。

视线驱动的主动光路对齐。 系统计划在眼镜端集成双目眼动追踪模块，标定眼动坐标、头部姿态和光束坐标之间的变换，并驱动可调光学发射单元主动追随视线。评估将重点考察多目标间距、对象或用户运动、标定误差和设备滑移对目标绑定的影响。该模块与图 ?? 一一对应，图片将展示从眼球测量到光束落点和目标回波确认的坐标变换链。

眼脑联合的操作意图判别。 系统计划同步采集眼动与水凝胶电极脑电，分别提取空间注视、停留行为和事件驱动神经特征，通过多模态融合区分自然观察、状态查看与主动操作，并保留显式确认作为低成本基线。该设计不预设脑电必然优于眼动，而是通过眼动单模态、脑电单模态、眼脑融合和显式确认之间的消融比较，判断脑电是否提供稳定的增量信息。

光学选择与无线会话协同。 系统计划以定向光完成目标发现、身份核验和初始授权，再把光学目标标识绑定到唯一蓝牙身份，由蓝牙维持后续命令与反馈。协议需要处理目标切换、授权超时、光路暂时中断、重新绑定和会话恢复，并保证无线阶段持续操作的对象仍是先前经过光学核验的物理实体。

3.5.5 系统验证

目前已完成总体架构、研究问题和评估指标设计，眼镜原型、融合模型和混合链路协议仍待完成。系统实验将分别评估视线驱动光束的目标选择准确率与错选率、不同距离和目标间距下的对齐性能、光学身份核验时延、由光学链路切换到蓝牙会话的时延、遮挡后的会话恢复时间，以及眼镜端功耗和温升。实验还将通过固定光束与视线驱动光束对照、不同标定误差和设备滑移条件，区分眼动对齐模块本身带来的收益。

3.5.6 用户实验

用户研究将围绕多对象自然观察和主动操作任务展开，对比显式手势确认、仅使用眼动、仅使用脑电以及眼脑融合等条件。研究重点包括任务完成时间、目标错选、无意触发、漏触发和会话中断，同时记录主观工作负荷、佩戴负担、信任和可接受性。对于脑电模块，评价目标不仅是分类指标，还包括其相对于眼动和显式确认所带来的实际交互增益是否足以抵偿额外佩戴成本。

3.5.7 小结

Omnisight 在 RetroAR 和 EchoSight 已验证的方向性对象绑定基础上，把研究问题推进到真实注视、操作意图和持续会话三个层次。当前工作已形成与三项设计一一对应的系统方案和验证计划，但尚未完成原型与实验，因此本节只陈述拟实现机制、对照条件和评价指标，不报告系统性能或用户研究结论。完成后计划将相关成果投稿至 ACM IMWUT 或 Nature Biomedical Engineering。

第四章 研究计划

4.1 论文提纲

计划中最终完成的学位论文将分为五章。全文以“注意力如何转化为可靠、可执行的定向交互”为主线，按照注意力线索由间接到直接、系统能力由对象绑定到双向交互再到持续闭环的顺序展开三项工作。各章内容安排如下：

第一章引言：从具身智能与人机共生的发展出发，提出多对象环境中的注意力驱动定向交互问题，分析注意目标解析、物理-数字身份对齐和交互闭环保持三项核心挑战，并建立“外化指向—贴近观察—解析意图”的递进研究框架。

第二章面向手持终端的指向交互：介绍§3.2中所介绍的“RetroAR：基于手机指向的可见光非接触定向交互系统”的设计、实现与评估相关内容，验证“所指即所控”。

第三章面向AR眼镜的视线交互：介绍§3.2中所介绍的“EchoSight：面向智能眼镜的双向近红外直观交互系统”的设计、实现与评估相关内容，验证“所见即所控”。

第四章面向未来穿戴设备的意图交互：介绍§3.2中所介绍的“Omnisight：眼脑联合的注意力驱动意图交互系统”的设计、实现与评估相关内容，检验“所思即所控”。

第五章总结与展望：总结三项工作的演进，归纳注意力驱动定向交互的设计原则，并讨论其在水机共生环境中的后续研究方向。

4.2 时间进度安排

在前述三项工作中，RetroAR 与 EchoSight 的系统设计、原型实现和实验评估已经完成；Omnisight 已完成总体架构、研究问题和评估指标设计，原型模块也已设计完成。围绕 Omnisight 研究和学位论文撰写，计划设置以下四个时间节点：

1. 在 2026 年 10 月 31 日以前，完成双目眼动追踪、光学波束控制和脑电采集模块的接入和原型功能性整合，完成光学部分性能测试和优化。
2. 在 2026 年 11 月 30 日以前，完成眼动、脑电联合的意图判别模型以及系统原型的端到端综合性能测试。
3. 在 2026 年 12 月 30 日以前，完成实际应用场景下的完整任务用户研究，完成投稿。

以上工作完成后，剩余任务是完成学位论文的撰写，计划在 2027 年 3 月 31 日以前完成。

参考文献

- [1] 中华人民共和国国家发展和改革委员会。中华人民共和国国民经济和社会发展第十五个五年规划纲要。2026-03。 <https://www.ndrc.gov.cn/fggz/fzzlgh/gjfzgh/202603/U020260317369114704096.pdf>, 访问于 2026-09-22。
- [2] 国务院。关于深入实施“人工智能+”行动的意见。2025-08-21, 国发〔2025〕11号。 https://www.gov.cn/zhengce/content/202508/content_7037861.htm, 访问于 2026-09-20。
- [3] 国家发展和改革委员会高技术司。人工智能赋能社会治理：人机共生的全新图景。2025-08-26。 https://www.ndrc.gov.cn/xxgk/jd/jd/202508/t20250826_1400071.html, 访问于 2026-09-20。
- [4] The White House. *America's AI Action Plan*. 2025-07. <https://www.whitehouse.gov/wp-content/uploads/2025/07/Americas-AI-Action-Plan.pdf>, accessed on 2026-09-20.
- [5] European Commission. *Apply AI Strategy*. 2025-10-08. <https://digital-strategy.ec.europa.eu/en/policies/apply-ai>, accessed on 2026-09-20.
- [6] 国家税务总局办公厅。税收数据显示：我国具身智能产业总体发展向好。2026-06-30。 <https://www.chinatax.gov.cn/chinatax/n810219/n810724/c5250672/content.html>, 访问于 2026-09-20。
- [7] 魏梦佳, 阳娜。中国具身智能迎来规模化应用关键窗口期。2026-08-24。 https://www.digitalchina.gov.cn/2026/xwzx/szcx/202608/t20260824_5362593.htm, 访问于 2026-09-20。
- [8] BMW Group. *First Humanoid Robot Introduced in Plant Leipzig*. 2026-03-09. <https://www.bmwgroup.com/en/news/general/2026/humanoid-robot-in-leipzig.html>, accessed on 2026-09-20.
- [9] Scarlett Evans. *Physical AI's Challenge: Making Humanoid Robots Work in the Real World*. 2026-09-15. <https://www.techtarget.com/ai/news/366650269/Physical-AIs-challenge-Making-humanoid-robots-work-in-the-real-world>, accessed on 2026-09-20.
- [10] Michael I. Posner. "Orienting of Attention". *Quarterly Journal of Experimental Psychology*, **1980**, 32(1): 3–25.
- [11] Richard A. Bolt. "'Put-That-There': Voice and Gesture at the Graphics Interface". In: *Proceedings of the 7th Annual Conference on Computer Graphics and Interactive Techniques*. **1980**: 262–270.
- [12] Robert J. K. Jacob. "What You Look At Is What You Get: Eye Movement-Based Interaction Techniques". In: *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*. **1990**: 11–18.
- [13] David Garlan, Daniel P. Siewiorek, Asim Smailagic et al. "Project Aura: Toward Distraction-Free Pervasive Computing". *IEEE Pervasive Computing*, **2002**, 1(2): 22–31.
- [14] Roel Vertegaal. "Attentive User Interfaces". *Communications of the ACM*, **2003**, 46(3): 30–33.

- [15] Jeffrey S. Shell, Roel Vertegaal, Aadil Mamuji *et al.* “*EyePliances and EyeReason: Using Attention to Drive Interactions with Ubiquitous Appliances*”. In: *Adjunct Proceedings of the 16th Annual ACM Symposium on User Interface Software and Technology*. **2003**. <https://uist.hosting.acm.org/archive/adjunct/2003/pdf/demos/d12-shell.pdf>, accessed on 2026-09-20.
- [16] Mihai Bâce, Teemu Leppänen, Argenis Ramirez Gomez *et al.* “*ubiGaze: Ubiquitous Augmented Reality Messaging Using Gaze Gestures*”. In: *SIGGRAPH ASIA 2016 Mobile Graphics and Interactive Applications*. **2016**. 11.
- [17] Ken Pfeuffer, Benedikt Mayer, Diako Mardanbegi *et al.* “*Gaze + Pinch Interaction in Virtual Reality*”. In: *Proceedings of the 5th Symposium on Spatial User Interaction*. **2017**: 99–108.
- [18] Adrian A. de Freitas, Michael Nebeling, Xiang Anthony Chen *et al.* “*Snap-To-It: A User-Inspired Platform for Opportunistic Device Interactions*”. In: *Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems*. **2016**: 5909–5920.
- [19] Ke Huo, Yuanzhi Cao, Sang Ho Yoon *et al.* “*Scenariot: Spatially Mapping Smart Things within Augmented Reality Scenes*”. In: *Proceedings of the 2018 CHI Conference on Human Factors in Computing Systems*. **2018**: 1–13.
- [20] Tengxiang Zhang, Zitong Lan, Chenren Xu *et al.* “*Bleselect: Gestural iot device selection via bluetooth angle of arrival estimation from smart glasses*”. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, **2023**, 6(4): 1–28.
- [21] Ethan Wilson, Naveen Sendhilnathan, Charlie S. Burlingham *et al.* “*Eye Gaze as a Signal for Conveying User Attention in Contextual AI Systems*”. In: *Proceedings of the 2025 Symposium on Eye Tracking Research and Applications*. **2025**. 119.
- [22] Microsoft. *Gaze and Dwell*. 2022-07-19. <https://learn.microsoft.com/en-us/windows/mixed-reality/design/gaze-and-dwell>, accessed on 2026-09-20.
- [23] Apple. *Get Started with visionOS*. 2026-09-17. <https://developer.apple.com/visionos/get-started/>, accessed on 2026-09-20.
- [24] Anna Maria Feit, Shane Williams, Arturo Toledo *et al.* “*Toward Everyday Gaze Input: Accuracy and Precision of Eye Tracking and Implications for Design*”. In: *Proceedings of the 2017 CHI Conference on Human Factors in Computing Systems*. **2017**: 1118–1130.
- [25] Weichen Liu, Gianna Andrade, Jürgen Schulze *et al.* “*Evaluation of Gaze-to-Object Mapping Algorithms for Use in “Real-World” Translatable Neuropsychological Paradigms*”. *Psychology & Neuroscience*, **2023**, 16(4): 339–348.
- [26] Ken Pfeuffer, Hans Gellersen and Mar Gonzalez-Franco. “*Design Principles and Challenges for Gaze + Pinch Interaction in XR*”. *IEEE Computer Graphics and Applications*, **2024**, 44(3): 74–81.
- [27] Hirokazu Kato and Mark Billinghurst. “*Marker Tracking and HMD Calibration for a Video-Based Augmented Reality Conferencing System*”. In: *Proceedings of the 2nd IEEE and ACM International Workshop on Augmented Reality*. **1999**: 85–94.
- [28] Hongshen Ma and Joseph A Paradiso. “*The FindIT Flashlight: Responsive tagging based on optically triggered microprocessor wakeup*”. In: *International conference on Ubiquitous Computing*. **2002**: 160–167.

- [29] Jackie (Junrui) Yang and James A. Landay. “InfoLED: Augmenting LED Indicator Lights for Device Positioning and Communication”. In: *Proceedings of the 32nd Annual ACM Symposium on User Interface Software and Technology*. **2019**: 175–187.
- [30] Karan Ahuja, Sujeath Paredy, Robert Xiao *et al.* “LightAnchors: Appropriating Point Lights for Spatially-Anchored Augmented Reality Interfaces”. In: *Proceedings of the ACM Symposium on User Interface Software and Technology*. **2019**: 189–196.
- [31] IEEE Standards Association. *IEEE 802.15.7-2011: Short-Range Wireless Optical Communication Using Visible Light*. 2011-06-16. <https://standards.ieee.org/ieee/802.15.7/5154/>, accessed on 2026-09-20.
- [32] Harald Haas, Liang Yin, Yunlu Wang *et al.* “What Is LiFi?” *Journal of Lightwave Technology*, **2016**, 34(6): 1533–1544.
- [33] Signify. *Signify Launches Trulifi*. 2019-06-19. <https://www.signify.com/global/our-company/news/press-releases/2019/20190619-signify-launches-trulifi>, accessed on 2026-09-20.
- [34] IEEE 802.11 Working Group. *IEEE Std 802.11bb-2023: Light Communications*. 2023-11-10. <https://grouper.ieee.org/groups/802/11/overview.html>, accessed on 2026-09-20.
- [35] Jiangtao Li, Angli Liu, Guobin Shen *et al.* “Retro-VLC: Enabling Battery-Free Duplex Visible Light Communication for Mobile and IoT Applications”. In: *Proceedings of the 16th International Workshop on Mobile Computing Systems and Applications*. **2015**: 21–26.
- [36] Xieyang Xu, Yang Shen, Junrui Yang *et al.* “PassiveVLC: Enabling Practical Visible Light Backscatter Communication for Battery-free IoT Applications”. In: *Proceedings of the 23rd Annual International Conference on Mobile Computing and Networking*. **2017**: 180–192.
- [37] Yue Wu, Purui Wang, Kenuo Xu *et al.* “TurboBoosting Visible Light Backscatter Communication”. In: *Proceedings of the Annual Conference of the ACM Special Interest Group on Data Communication on the Applications, Technologies, Architectures, and Protocols for Computer Communication*. **2020**: 186–197.
- [38] Xiping Wu, Mohammad Dehghani Soltani, Lai Zhou *et al.* “Hybrid LiFi and WiFi Networks: A Survey”. *IEEE Communications Surveys & Tutorials*, **2021**, 23(2): 1398–1420.
- [39] Samuel David Perli, Nabeel Ahmed and Dina Katabi. “PixNet: Interference-free Wireless Links Using LCD-camera Pairs”. In: *Proceedings of the 16th Annual International Conference on Mobile Computing and Networking*. **2010**: 137–148.
- [40] Kenuo Xu, Chen Gong, Bo Liang *et al.* “Low-Latency Visible Light Backscatter Networking with RetroMUMIMO”. In: *Proceedings of the 20th ACM Conference on Embedded Networked Sensor Systems*. **2022**: 448–461.
- [41] Seyed Keyarash Ghiasi and Marco Zuniga. “Exploiting Polarization and Color to Enable MIMO Backscattering with Light”. In: *Proceedings of the 22nd ACM Conference on Embedded Networked Sensor Systems*. **2024**: 771–783.

- [42] Yanxiang Wang, Yiran Shen, Kenuo Xu *et al.* “Towards High-Speed Passive Visible Light Communication with Event Cameras and Digital Micro-Mirrors”. In: *Proceedings of the 22nd ACM Conference on Embedded Networked Sensor Systems*. **2024**: 704–717.
- [43] Domenico Giustiniano, Ambuj Varshney and Thiemo Voigt. “Connecting Battery-Free IoT Tags Using LED Bulbs”. In: *Proceedings of the 17th ACM Workshop on Hot Topics in Networks*. **2018**: 99–105.
- [44] Boxuan Xie, Alexis A. Dowhuszko, Kalle Koskinen *et al.* “Integration of Visible Light and Backscatter Communications for Ambient Internet of Things”. In: *2024 IEEE 99th Vehicular Technology Conference (VTC2024-Spring)*. **2024**: 1–6.
- [45] Kalle Koskinen, Boxuan Xie, Kalle Ruttik *et al.* “Li2BC: From Visible Light Communication to Ambient RF Backscatter”. In: *2025 16th German Microwave Conference (GeMiC)*. **2025**: 346–349.
- [46] Boxuan Xie, Yifan Zhang, Kalle Koskinen *et al.* “Joint Visible Light and RF Backscatter Communications for Ambient IoT Network: Fundamentals, Applications, and Opportunities”. *arXiv preprint arXiv:2603.04626*, **2026**.
- [47] Daniel Wagner, Gerhard Reitmayr, Alessandro Mulloni *et al.* “Real-Time Detection and Tracking for Augmented Reality on Mobile Phones”. *IEEE Transactions on Visualization and Computer Graphics*, **2010**, 16(3): 355–368.
- [48] Chengyuan Xu, Radha Kumaran, Noah Stier *et al.* “Multimodal 3D Fusion and In-Situ Learning for Spatially Aware AI”. In: *2024 IEEE International Symposium on Mixed and Augmented Reality*. **2024**: 485–494.
- [49] Adrian A de Freitas, Michael Nebeling, Akshaye Shreenithi Kirupa Karthikeyan Ranithangam *et al.* “Bluewave: enabling opportunistic context sharing via bluetooth device names”. In: *Proceedings of the 8th ACM SIGCHI Symposium on Engineering Interactive Computing Systems*. **2016**: 38–49.
- [50] Maruchi Kim, Antonio Glenn, Bandhav Veluri *et al.* “IRIS: Wireless Ring for Vision-Based Smart Home Interaction”. In: *Proceedings of the 37th Annual ACM Symposium on User Interface Software and Technology*. **2024**. 114.
- [51] Fengyuan Zhu and Tovi Grossman. “BISHARE: Exploring Bidirectional Interactions Between Smartphones and Head-Mounted Augmented Reality”. In: *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*. **2020**: 1–14.
- [52] Hiroki Kaimoto, Kyzyl Monteiro, Mehrad Faridan *et al.* “Sketched Reality: Sketching Bi-Directional Interactions Between Virtual and Physical Worlds with AR and Actuated Tangible UI”. In: *Proceedings of the 35th Annual ACM Symposium on User Interface Software and Technology*. **2022**. 1.
- [53] Zhengzhe Zhu, Ziyi Liu, Tianyi Wang *et al.* “MechARspace: An Authoring System Enabling Bidirectional Binding of Augmented Reality with Toys in Real-Time”. In: *Proceedings of the 35th Annual ACM Symposium on User Interface Software and Technology*. **2022**. 50.
- [54] Tim Schreiter, Andrey Rudenko, Martin Magnusson *et al.* “Human Gaze and Head Rotation during Navigation, Exploration and Object Manipulation in Shared Environments with Robots”. In: *2024 33rd IEEE International Conference on Robot and Human Interactive Communication*. **2024**: 1258–1265.

-
- [55] Lawrence A. Farwell and Emanuel Donchin. “Talking off the Top of Your Head: Toward a Mental Prosthesis Utilizing Event-Related Brain Potentials”. *Electroencephalography and Clinical Neurophysiology*, **1988**, 70(6): 510–523.
- [56] Xiaogang Chen, Yijun Wang, Shangkai Gao *et al.* “Filter bank canonical correlation analysis for implementing a high-speed SSVEP-based brain–computer interface”. *Journal of Neural Engineering*, **2015**, 12(4): 046008.
- [57] Shangkai Gao, Yijun Wang, Xiaorong Gao *et al.* “Visual and Auditory Brain–Computer Interfaces”. *IEEE Transactions on Biomedical Engineering*, **2014**, 61(5): 1436–1447.
- [58] Xiu Miao and Wenjun Hou. “Human–Computer Interaction Multi-Task Modeling Based on Implicit Intent EEG Decoding”. *Applied Sciences*, **2024**, 14(1). 368.
- [59] Xiaotong Gu, Zehong Cao, Alireza Jolfaei *et al.* “EEG-Based Brain-Computer Interfaces (BCIs): A Survey of Recent Studies on Signal Sensing Technologies and Computational Intelligence Approaches and Their Applications”. *IEEE/ACM Transactions on Computational Biology and Bioinformatics*, **2021**, 18(5): 1645–1666.
- [60] 王崴, 赵敏睿, 高虹霓 等。“基于脑电和眼动信号的人机交互意图识别”。*航空学报*, **2021**, 42(2): 324290。
- [61] Z Yi, J Pan, Z Chen *et al.* “A Hybrid BCI Integrating EEG and Eye-Tracking for Assisting Clinical Communication in Patients With Disorders of Consciousness”. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, **2024**, 32: 2759–2771.
- [62] Parag Khanna, Nona Rajabi, Sumeyra U. Demir Kanik *et al.* “Early Detection of Human Handover Intentions in Human–Robot Collaboration: Comparing EEG, Gaze, and Hand Motion”. *Robotics and Autonomous Systems*, **2026**, 196. 105244.
- [63] Yeshan Zhu, Wei Wang, Sina Dang *et al.* “Research on Multimodal Interaction Intention Recognition Based on EEG, Eye Movement, and Gesture Signals”. *Scientific Reports*, **2026**, 16. 3834.